

# Sistemas de recomendación

*¿Es posible ayudar al usuario a encontrar información sin que la pida?*

*¿Cómo personalizar el proceso?*

# Sistemas de recomendación



Users who bought this also bought...



Related videos



Music discovery



People you may know...



...

Your Amazon.com x

Secure | [https://www.amazon.com/gp/yourstore/home/ref=nav\\_cs\\_ys](https://www.amazon.com/gp/yourstore/home/ref=nav_cs_ys)

## Recommended for you, Pablo

**THE DIGITAL DIVIDE**  
Arguments for and Against Facebook, Google, Twitter, and the Age of Social Networking  
Steven Johnson, Nicholas Carr, David Foray, Douglas Rushkoff, Maggie Jackson, Clay Shirky, & Todd Gitlin  
Mark Berman, introducing author of THE WINNERS' GENERATION

Engineering Books  
31 ITEMS

**ASTRA TAYLOR THE PEOPLE'S PLATFORM**  
TAKING BACK POWER AND CULTURE IN THE DIGITAL AGE  
ASTRA TAYLOR  
DIRECTOR OF JESSIE AND JOHNNY'S LIFE

Art & Photography Books  
7 ITEMS

**THE GO-GIVER**  
A LITTLE STORY ABOUT A POWERFUL BUSINESS IDEA  
Bob Burg and John David Mann

Self-Help Books  
24 ITEMS

**EDWARD O. THORP A MAN FOR ALL MARKETS**  
FROM LAS VEGAS TO WALL STREET, HOW I BEAT THE DEALER AND THE MARKET  
EDWARD O. THORP  
AUTHOR OF BEATING THE DEALER

Humor & Entertainment Books  
23 ITEMS

**BLUR**  
HOW TO KNOW WHAT'S TRUE IN THE AGE OF INFORMATION OVERLOAD  
BILL KOVACH AND TOM ROSENSTIEL  
AUTHORS OF THE NOISE

Reference Books  
21 ITEMS

**MICHAEL LEWIS THE UNDOING PROJECT**  
A FRIENDSHIP THAT CHANGED OUR MINDS  
MICHAEL LEWIS  
AUTHOR OF THE BIG SHORT

Biographies & Memoirs  
7 ITEMS

**ARRIVAL**  
JULIA FURTERMAN  
ANNE HATHAWAY, JAMES FRANCO, FREDRICK WU  
DIRECTED BY JACOB VERHOEVEN

Movies & TV  
53 ITEMS

**annie hall**  
WOODY ALLEN, DIANE KEATON  
DIRECTED BY WOODY ALLEN

Comedy in Video  
86 ITEMS

**FORCES OF NATURE**  
SANDRA BULLOCK, BEN AFFLECK  
DIRECTED BY JAMES HAMILTON

Romance in Video  
26 ITEMS



## Abbey Road (Remastered) [Enhanced, Limited Edition, Original Recording Remastered]

The Beatles | Format: Audio CD

★★★★☆ (1,260 customer reviews) | Like (42)

Price: **\$13.88** & eligible for **FREE Super Saver Shipping** on orders over \$25. [Details](#)

[Special Offers Available](#)

**In Stock.**

Ships from and sold by Amazon.com. Gift-wrap available.

**Want it delivered Tuesday, April 12?** Order it in the next **33 hours and 2 minutes**, and choose **One-Day Shipping** at checkout. [Details](#)

[57 new](#) from \$10.78 [16 used](#) from \$8.35 [1 collectible](#) from \$30.68

Quantity: 1

☐ Yes, I want **FREE Two-Day Shipping** with [Amazon Prime](#)

[Add to Cart](#)

or

[Sign in](#) to turn on 1-Click ordering.

[Add to Wish List](#)

**More Buying Choices**

**74 used & new** from \$8.35

Have one to sell? [Sell yours here](#)

[Share](#) [f](#) [t](#)

## Customers Who Bought This Item Also Bought

Page 1 of 12



Sgt. Pepper's Lonely Hearts Club Band (Remastered) ~ The Beatles  
★★★★☆ (1,325)  
\$14.49



Let It Be (Remastered) ~ The Beatles  
★★★★☆ (435)  
\$14.66



The White Album (Remastered) ~ The Beatles  
★★★★☆ (1,155)  
\$18.99



Revolver (Remastered) ~ The Beatles  
★★★★☆ (923)  
\$14.64



Rubber Soul (Remastered) ~ The Beatles  
★★★★☆ (725)  
\$14.49



Magical Mystery Tour (Remastered) ~ The Beatles  
★★★★☆ (531)  
\$14.85



Yellow Submarine (Remastered) ~ The Beatles  
★★★★☆ (1:)  
\$15.68



Help! (Remastered) ~ The Beatles  
★★★★☆ (280)  
\$14.73



A Hard Day's Night (Remastered) ~ The Beatles  
★★★★☆ (307)  
\$14.60



Please Please Me (Remastered) ~ The Beatles  
★★★★☆ (272)  
\$14.69



Dark Side of the Moon ~ Pink Floyd  
★★★★☆ (1,360)  
\$11.44



With The Beatles (Remastered) ~ The Beatles  
★★★★☆ (221)  
\$14.55



The Beatles Mono Box Set ~ The Beatles  
★★★★☆ (288)  
\$207.82



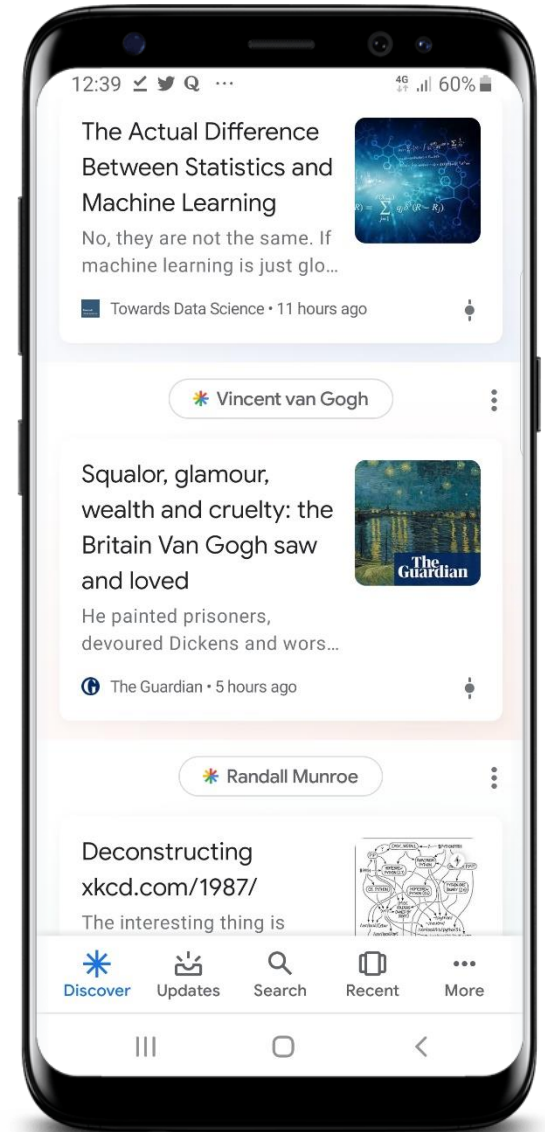
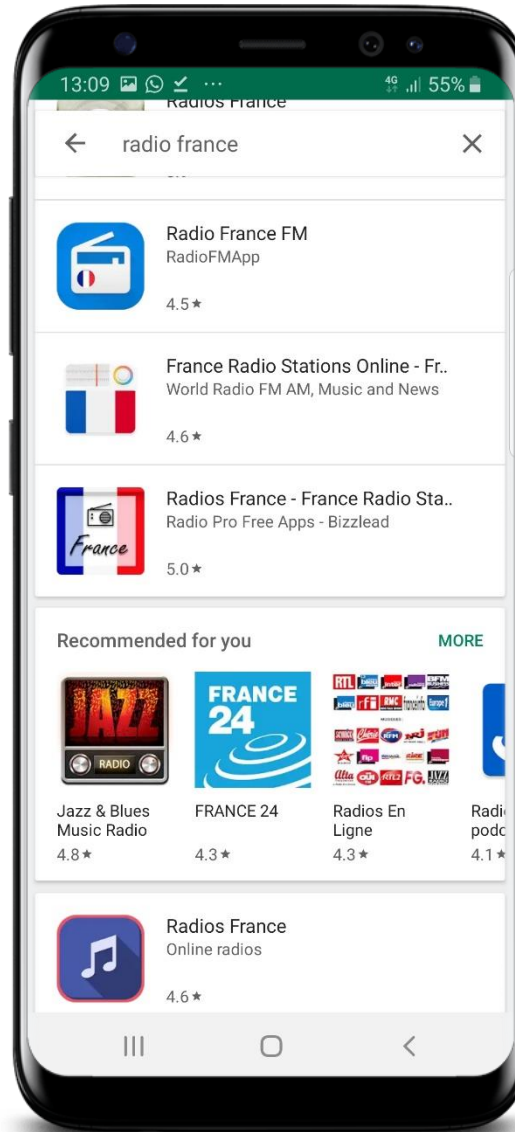
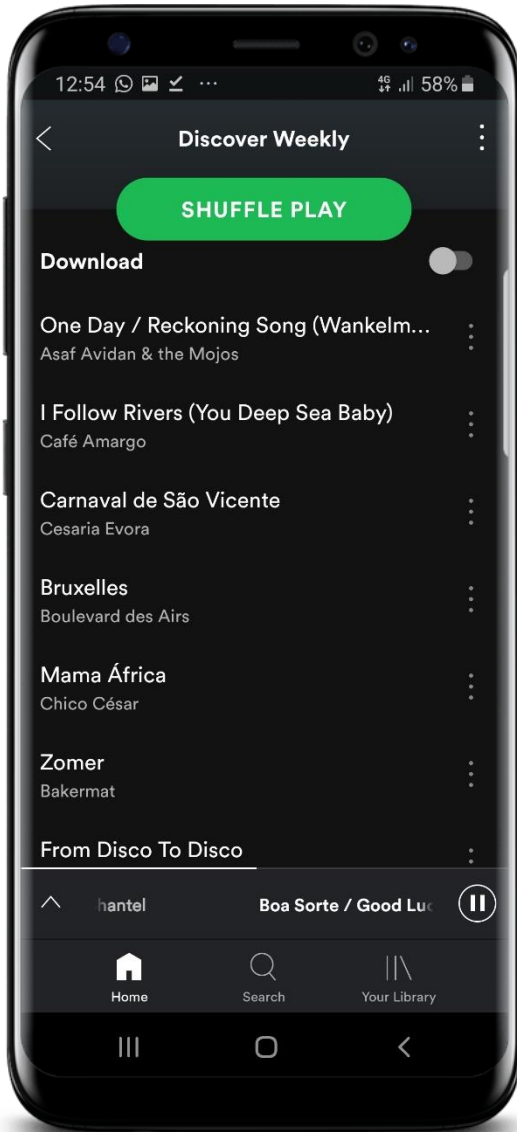
Beatles For Sale (Remastered) ~ The Beatles  
★★★★☆ (270)  
\$14.98



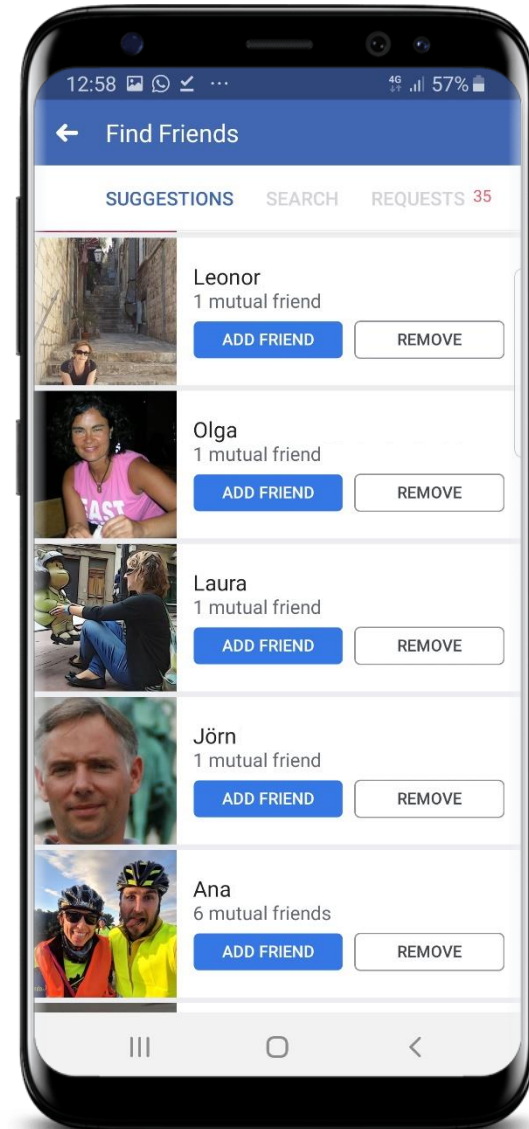
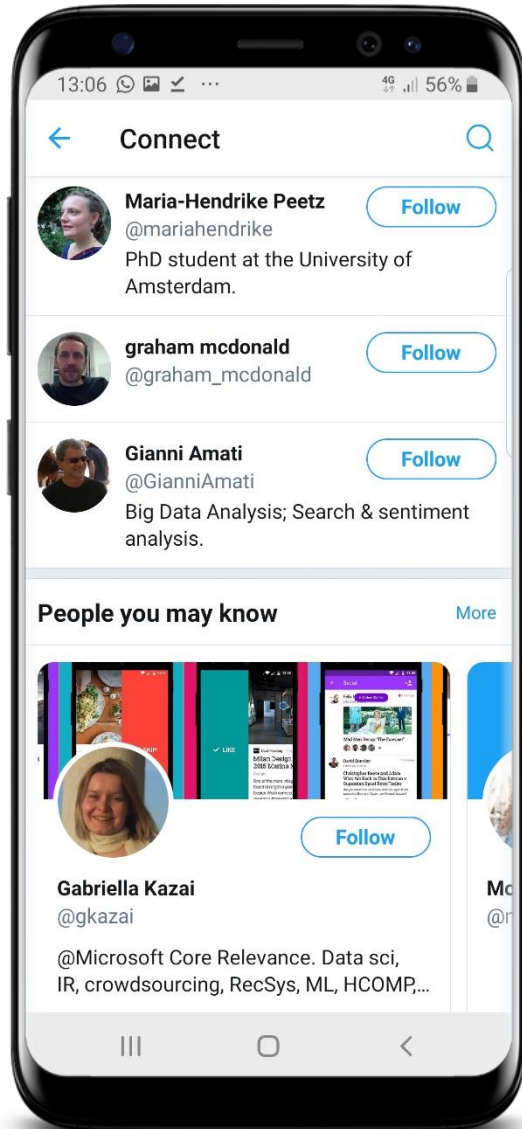
Are You Experienced (Vinyl) ~ Jimi Hendrix  
★★★★☆ (12)  
\$16.30



1967-1970 (Blue) Remastered ~ The Beatles  
★★★★☆ (34)  
\$16.49







# Tipos de recomendación

- ◆ Personalizada vs. no personalizada
- ◆ Contextual vs. fuera de contexto
- ◆ Formas de envío / presentación
  - En la misma aplicación (online) vs. por mail / notificaciones (offline)
  - En primer plano vs. lateral
  - Solicitada por el usuario vs. a iniciativa de la aplicación
- ◆ Tipo de objetos recomendados
  - Caso particular: otros usuarios en redes sociales

# Recomendación personalizada



Your Amazon.com x

Secure | [https://www.amazon.com/gp/yourstore/home/ref=nav\\_cs\\_ys](https://www.amazon.com/gp/yourstore/home/ref=nav_cs_ys)

Recommended for you, Pablo

**Engineering Books**  
31 ITEMS

**Art & Photography Books**  
7 ITEMS

**Self-Help Books**  
24 ITEMS

**Humor & Entertainment Books**  
23 ITEMS

**Reference Books**  
21 ITEMS

**Biographies & Memoirs**  
7 ITEMS

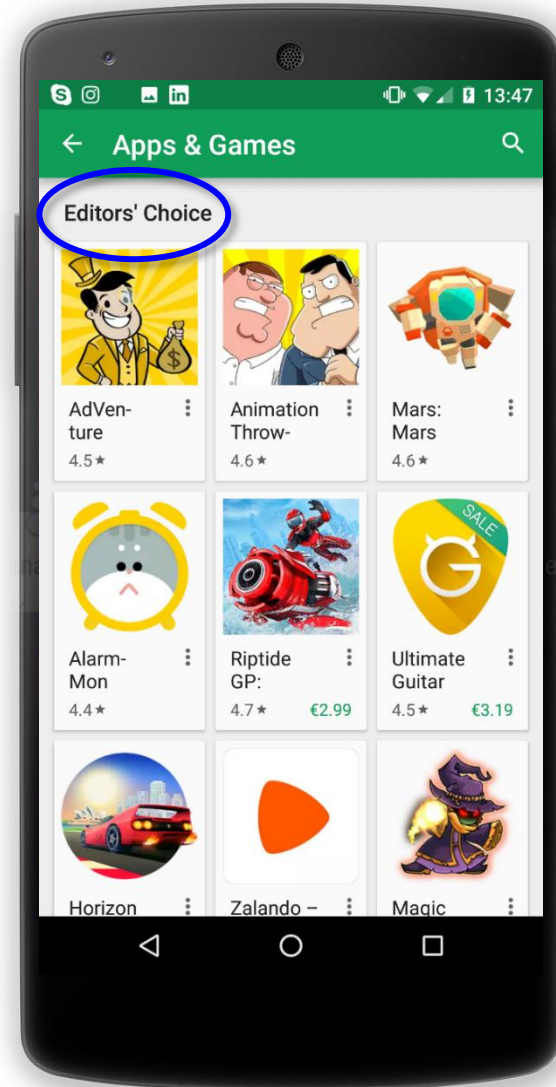

**Movies & TV**  
53 ITEMS

**Comedy in Video**  
86 ITEMS

**Romance in Video**  
26 ITEMS



# Recomendación no personalizada



# Recomendación contextual

amazon

Contexto

Google play

www.amazon.com/Abbey-Road-Remastered-Beatles/dp/B0023KVLUQ

Abbey Road (Remastered) [Enhanced, Limited Edition, Original Recording Remastered]

The Beatles | Format: Audio CD

★★★★★ (1,260 customer reviews) | Like (42)

Price: ~~\$13.88~~ & eligible for **FREE Super Saver Shipping** on orders over \$25. [Details](#)

[Special Offers Available](#)

**In Stock.**

Ships from and sold by Amazon.com. Gift-wrap available.

**Want it delivered Tuesday, April 12?** Order it in the next 33 hours and 2 minutes, and choose **One-Day Shipping** at check

[57 new](#) from \$10.78 [16 used](#) from \$8.35 [1 collectible](#) from \$30.68



Customers Who Bought This Item Also Bought



Sgt. Pepper's Lonely Hearts Club Band (Remastered) ~ The Beatles

★★★★★ (435)

★★★★★ (1,325)

\$14.49



Let It Be (Remastered) ~ The Beatles

★★★★★ (435)

\$14.66



The White Album (Remastered) ~ The Beatles

★★★★★ (1,155)

\$18.99



Revolver (Remastered) ~ The Beatles

★★★★★ (923)

\$14.64



Rubber Soul (Remastered) ~ The Beatles

★★★★★ (725)

\$14.49



Magical Mystery Tour (Remastered) ~ The Beatles

★★★★★ (531)

\$14.85



A Hard Day's Night (Remastered) ~ The Beatles

★★★★★ (307)

\$14.60



Please Please Me (Remastered) ~ The Beatles

★★★★★ (272)

\$14.69



Dark Side of the Moon ~ Pink Floyd

★★★★★ (1,360)

\$11.44



With The Beatles (Remastered) ~ The Beatles

★★★★★ (221)

\$14.55



The Beatles Mono Box Set ~ The Beatles

★★★★★ (288)

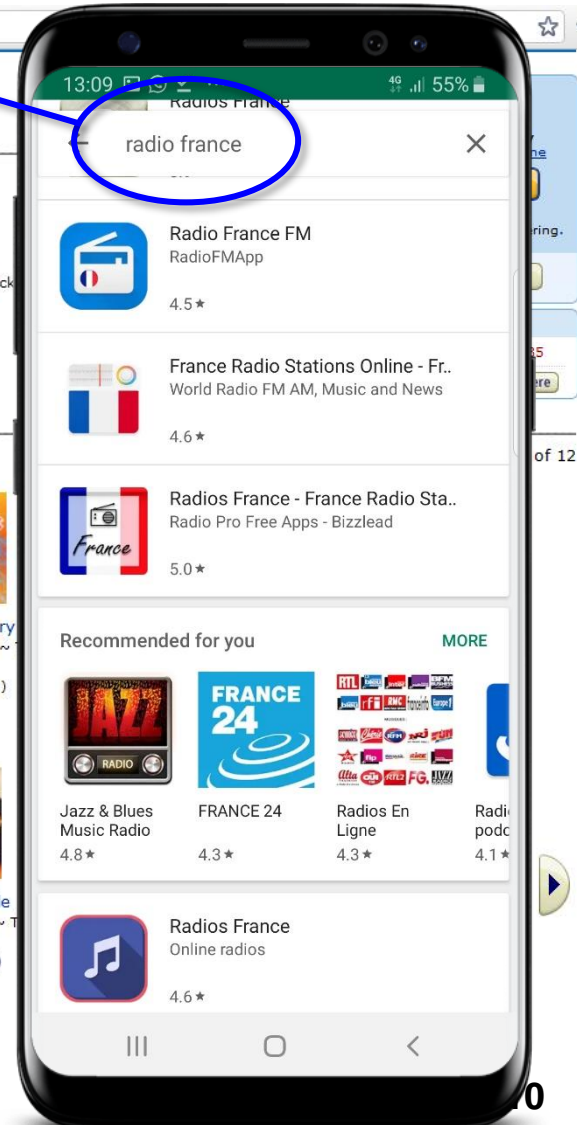
\$207.82



Beatles For Sale (Remastered) ~ The Beatles

★★★★★ (270)

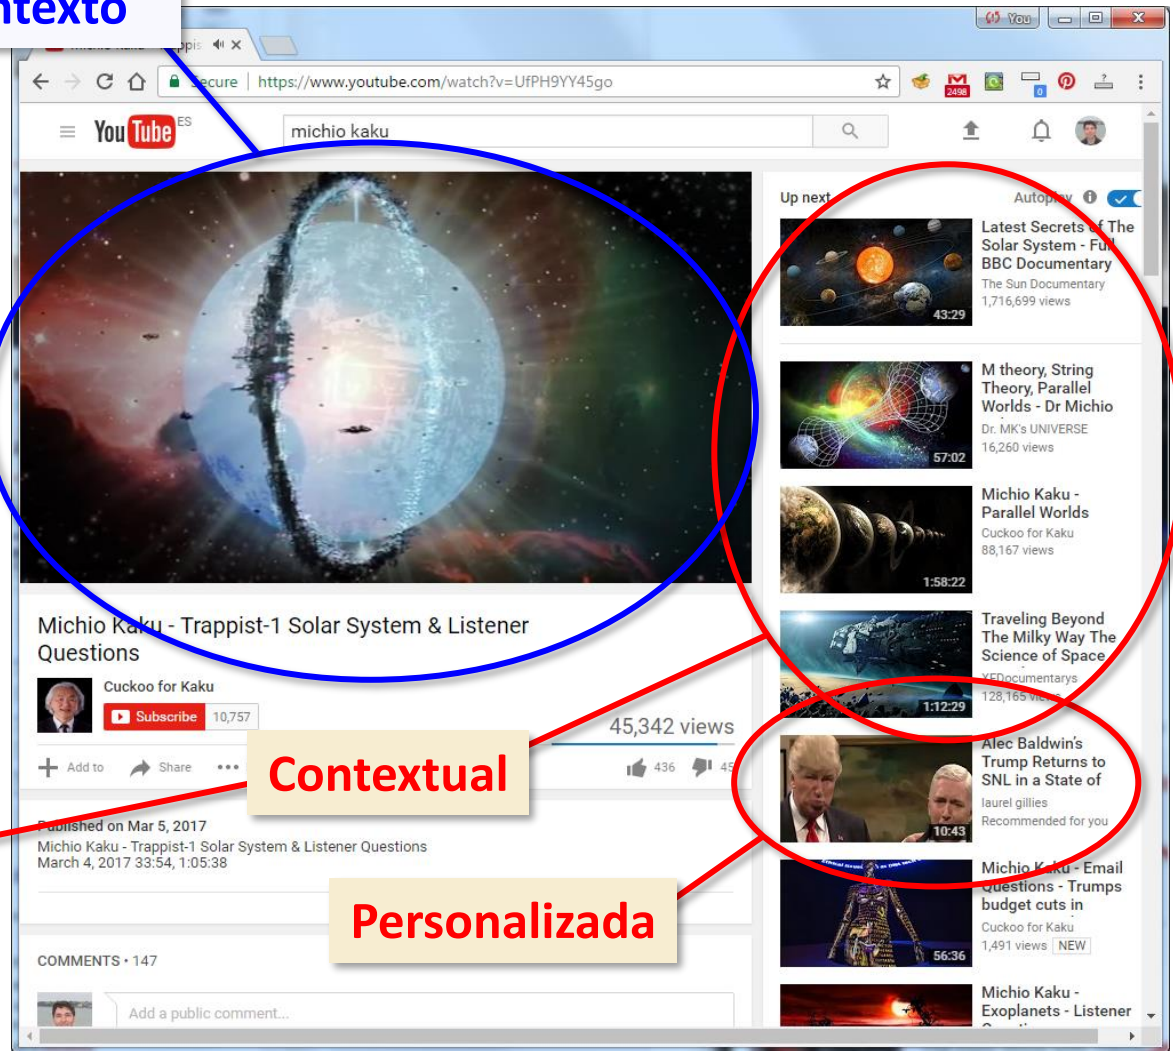
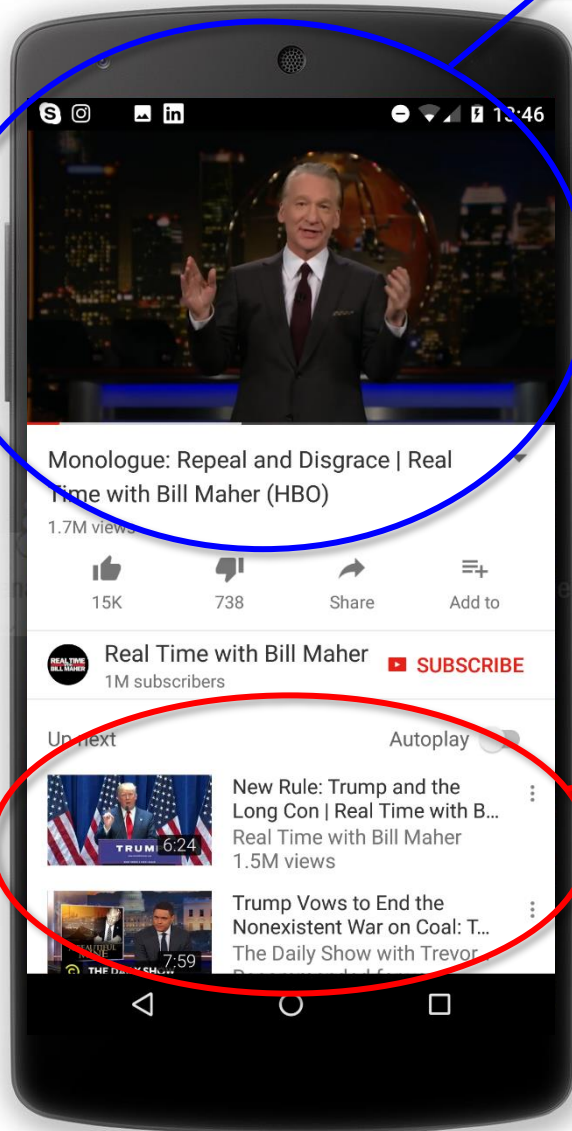
\$14.98



# Recomendación contextual / personalizada

YouTube

Contexto



Contextual

Personalizada

1<sup>er</sup> vs. 2<sup>o</sup> plano

2<sup>o</sup> plano





## Pablo Castells

529 Tweets



Edit profile

### Pablo Castells

@pcastells

Associate Professor at Universidad Autónoma de Madrid

Madrid, Spain [ir.ii.uam.es/castells](https://ir.ii.uam.es/castells) Joined June 2009

332 Following 673 Followers

Tweets

Tweets & replies

Media

Likes

You Retweeted



**Rocío Cañamares** @rcanamares · Mar 9

Preprint of our [@SpringerIRJ](#) paper with [@pcastells](#) and Alistair Moffat "Offline Evaluation Options for Recommender Systems", is available at [ir.ii.uam.es/pubs/irj2020.p...](https://ir.ii.uam.es/pubs/irj2020.p...)



9



15



You Retweeted



**ACMRecSys** @ACMRecSys · Mar 2

We are delighted to announce Ricardo Baeza-Yates ([@PolarBearby](#)) as a keynote speaker at [#RecSys2020](#) [https://www.acm.org/recsys2020/venue](#)

Search Twitter



### You might like



**Bárbara P**  
@bpoblete

Follow



**ExUM WS@...**  
@... Follows you

Follow



**sbourke**  
@sbourke

Follow

Show more

### Trends for you



Trending in Spain

**Camera Café**

Trending in Spain

**#GobiernoNegligente**

3,734 Tweets

2º plano

# Recomendación offline

The screenshot shows a Gmail interface with a single email from 'Quora Digest' in the inbox. The email title is 'How many milliseconds can a human remain alive exposed to the vacuum of space?'. The sender is 'Quora Digest <digest-noreply@quora.com>' and it was received on 'Mar 12 (3 days ago)'. The email content features the Quora logo and 'Pablo's Digest'. It lists 'TOP STORIES FOR YOU' with two articles:

- How many milliseconds can a human remain alive exposed to the vacuum of space?** by Valentin Ghincolov, Amateur astronomer, and really passionate about Relativity and physics. Updated Jan 22. The text states: 'Oh, again so many misconceptions and myths. TL:DR: consciousness lost in 8-15 seconds. Death after 1 to 3 minutes Successful CPR resuscitation after up to 6 minutes. Details:... [Read More »](#)'
- In medieval times, how were fully armoured knights killed?** by Jerimi Galligory, I read history books occasionally. Written 15h ago. The text states: 'I'm going to assume that by "fully armoured" you mean "full plate armour." So, this: There are three different ways you can counter this guy. The first choice would be to pou... [Read More »](#)'

A small image of a knight in full plate armor is visible next to the second article. The email is currently selected in the inbox, and the 'COMPOSE' button is visible on the left sidebar.



# La tarea de recomendación

- ♦ **IR sin consulta** explícita
  - “Buscar sin preguntar”
- ♦ Útil como complemento a la búsqueda por consulta
  - Cuando el espacio es masivo, muy dinámico
  - El usuario desconoce lo que puede buscar, tiene poco tiempo para ello y/o su necesidad es vaga
- ♦ Es el **sistema** quien toma la **iniciativa**
- ♦ El sistema necesita de todos modos evidencia (y una representación) de la necesidad de información del usuario

# La tarea de recomendación (cont)

Confluencia de dos (o más) campos

- ♦ Se puede ver como un caso particular de IR
- ♦ Pero también un problema de clasificación / aprendizaje automático

El sistema...

1. **Observa** al usuario mientras éste realiza actividades
2. **Detecta** patrones de comportamiento, identifica indicios de interés del usuario
3. **Predice y sugiere** al usuario opciones de interés
  - Predice intereses futuros basados en indicios de intereses pasados













# La tarea de recomendación (cont)


- ◆ Espacio de recuperación
  - Cualquier tipo de objeto útil que tenga sentido buscar: “ítems”
  - Documentos Web, productos (libros, películas, música, juegos, apps, ropa...), noticias, vídeos, servicios, eventos, ofertas de empleo, conversaciones, grupos, personas...
- ◆ Evidencia (indicios) de la necesidad de información
  - Típicamente consiste en interacción entre los usuarios y los objetos a recomendar, observada por el sistema: compras, inspección, play, click, like, puntuaciones, etc.
  - Pero puede ser cualquier otro tipo de actividad del usuario (la “traza digital”): búsquedas, navegación, posts, interacción social, etiquetas y comentarios asignados a ítems, etc.
  - Puede utilizarse también información propia del usuario: demográfica, geoposicional, etc.
  - Los algoritmos basados en contenido utilizan además datos de los ítems
- ◆ Dada toda esta evidencia, generar un ránking de ítems para cada usuario
  - Típicamente (pero no necesariamente) personalizado (i.e. distinto para cada usuario)

# Formulación de la tarea

- ♦ Interacción observada
  - P.e. los usuarios puntúan ítems  $r(u, i) \in \{1, 2, 3, 4, 5\}$
  - Unos pocos valores son observados
- ♦ Ordenar (ránking) los ítems con los que el usuario objetivo no ha interactuado
  - El sistema predice la puntuación  $\hat{r}(u, i)$  para pares usuario-ítem no observados

- Con ello se define un ránking de ítems para cada usuario  
→ recomendación

		<i>i</i>							Items
									
<i>u</i>		4		4	2		2	2	
		1	4	4		4			
		4	3	?	2	5	?	2	
		4	3	3			2		
			1	1	5	1	5	5	





Estructura del input de un sistema de recomendación

Abstracción de la interacción entre usuario e ítem...

# Algoritmos de recomendación

## ◆ Personalizados













- Basados en contenido 
- Filtrado colaborativo 
- Basados en red social
- Híbridos: combinaciones de los anteriores (ensembles, etc.), equilibran sus virtudes y debilidades

## ◆ No personalizados

- Popularidad y mayorías (p.e. top ventas, puntuación promedio, etc.)
- Críticas de expertos (p.e. guía del ocio, rotten tomatoes, etc.)
- Prioridades del proveedor




# Algoritmos de recomendación triviales

		$i$						
		Items						
								
$u$		4		4	2		2	2
		1	4	4		4		
		4	3	?	2	5	?	2
		4	3	3			2	2
			1	1	5	1	5	5

# Algoritmos de recomendación triviales

**Expert's opinion** (reviewers, etc.)

*i* Items



	4		4	2		2	2
	1	4	4		4		
<i>u</i>	4	3	1	2	5		2
	4	3				2	2
Users		1	1	5	1	5	5


$\hat{r}(u, i) = r(\text{expert}, i)$






Expert

# Algoritmos de recomendación triviales

**Expert's opinion** (reviewers, etc.)

*i* Items















<i>u</i>							
	4		4	2		2	2
	1	4	4		4		
	4	3	1	2	5	5	2
	4	3					2
		1	1	5	1	5	5

$\hat{r}(u, i) = r(\text{expert}, i)$

Expert

# Algoritmos de recomendación triviales













## Average

		<i>i</i>						
		Items						
								
<i>u</i>		4		4	2		2	2
		1	4	4		4		
		4	3	12/4	2	5		2
		4	3	3			2	2
			1	1	5	1	5	5

$$\hat{r}(u, i) = \frac{1}{\text{n}^\circ \text{ ratings de } i} \sum_{r(v, i) \neq \emptyset} r(v, i)$$

# Algoritmos de recomendación triviales

## Average













		<i>i</i>						
		Items						
								
<i>u</i>		4		4	2		2	2
		1	4	4		4		
		4	3	12/4	2	5	9/3	2
		4	3	3			2	2
			1	1	5	1	5	5

$$\hat{r}(u, i) = \frac{1}{\text{n}^\circ \text{ ratings de } i} \sum_{r(v, i) \neq \emptyset} r(v, i)$$



# Algoritmos de recomendación triviales

## Most popular

		<i>i</i>						
		Items						
								
<i>u</i>		4		4	2		2	2
		1	4	4		4		
		4	3	4/5	2	5		2
		4	3	3			2	2
			1	1	5	1	5	5













Función de ránking,  
no es interpretable  
como rating  $\hat{r}(u, i)$

↓

$$f(u, i) = \frac{\text{nº ratings } i}{\text{nº total de usuarios}}$$

# Algoritmos de recomendación triviales

## Most popular













		<i>i</i>						
		Items						
								
<i>u</i>		4		4	2		2	2
		1	4	4		4		
		4	3	4/5	2	5	3/5	2
		4	3	3			2	2
			1	1	5	1	5	5

Función de ránking,  
no es interpretable  
como rating  $\hat{r}(u, i)$

↓


$$f(u, i) = \frac{\text{nº ratings } i}{\text{nº total de usuarios}}$$

# Algoritmos de recomendación comunes

		$i$						
		Items						
								
$u$		4		4	2		2	2
		1	4	4		4		
		4	3	?	2	5	?	2
		4	3	3			2	2
			1	1	5	1	5	5


# Algoritmos de recomendación comunes

## Collaborative filtering: kNN, user-based



# Algoritmos de recomendación comunes

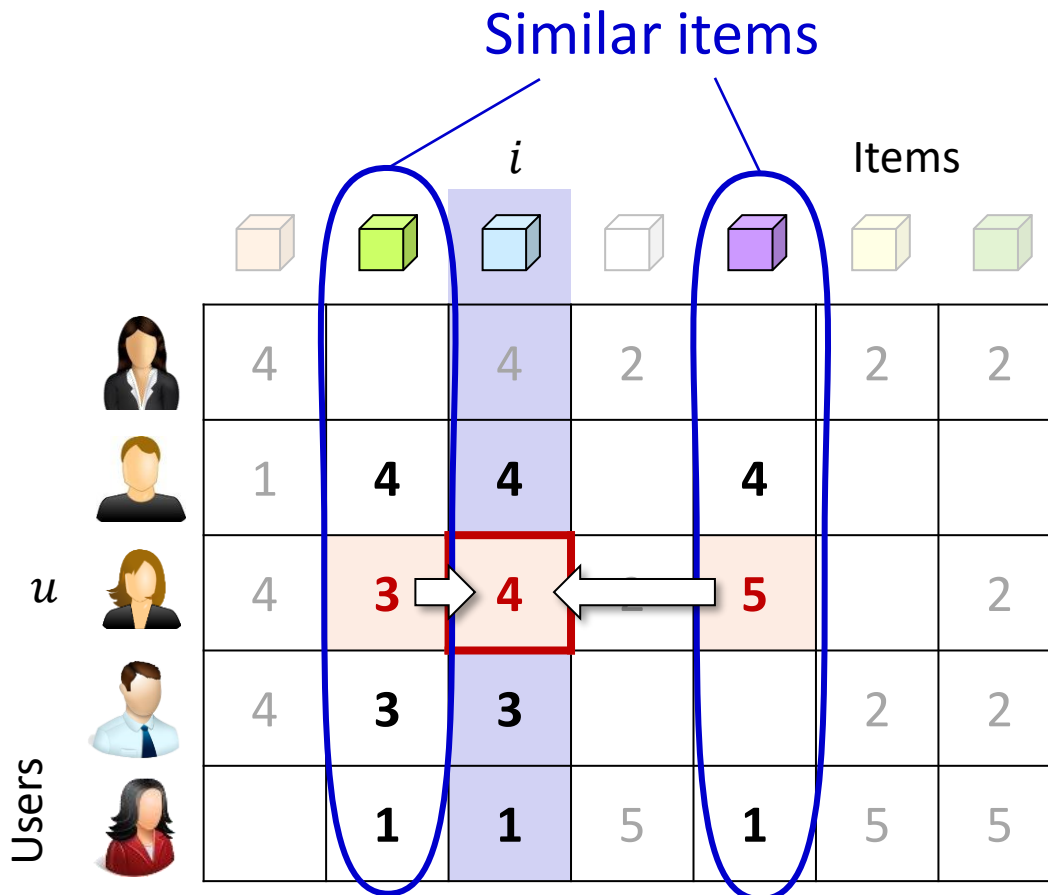
## Collaborative filtering: kNN, user-based





# Algoritmos de recomendación comunes


## Collaborative filtering: kNN, item-based



$$\hat{r}(u, i) = C \sum_{r(u, j) \neq \emptyset} sim(i, j) r(u, j)$$


# Algoritmos de recomendación comunes

## Collaborative filtering: kNN, item-based

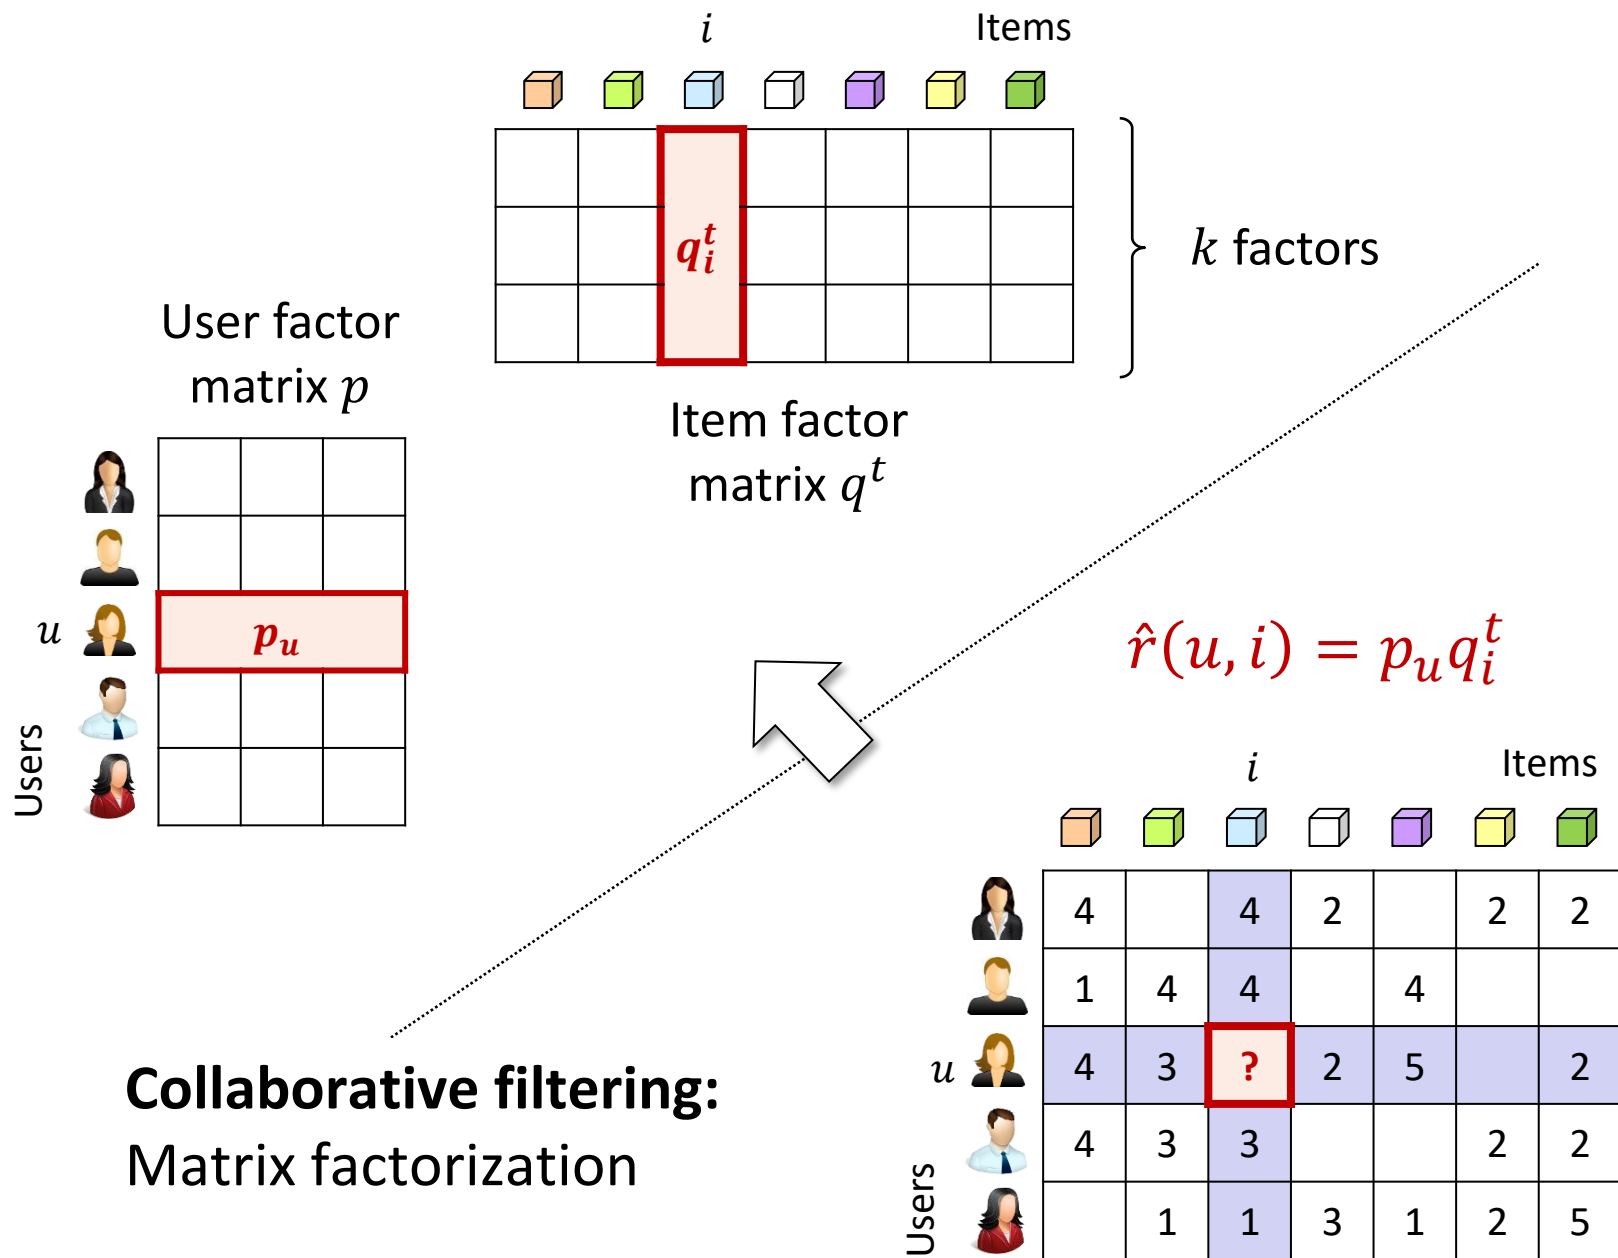


$$\hat{r}(u, i) = C \sum_{r(u, j) \neq \emptyset} sim(i, j) r(u, j)$$

# Algoritmos de recomendación comunes




$$\hat{r}(u, i) = C \sum_{r(u, j) \neq \emptyset} sim(i, j) r(u, j)$$



# Algoritmos en detalle

# Filtrado colaborativo

- ♦ Los usuarios se benefician de la experiencia de otros usuarios
- ♦ Métodos basados en memoria: vecinos próximos (kNN) 
  - Se basan en similitud entre usuarios o entre ítems
- ♦ Métodos basados en modelo
  - Modelos bayesianos
  - Regresión


} Usando ratings en las características  
(si no, serían basados en contenido)

- Factorización de matrices: muy diversos métodos
- Learning to rank
- Redes neuronales
- Y una amplísima variedad...

# Filtrado colaborativo: vecinos próximos

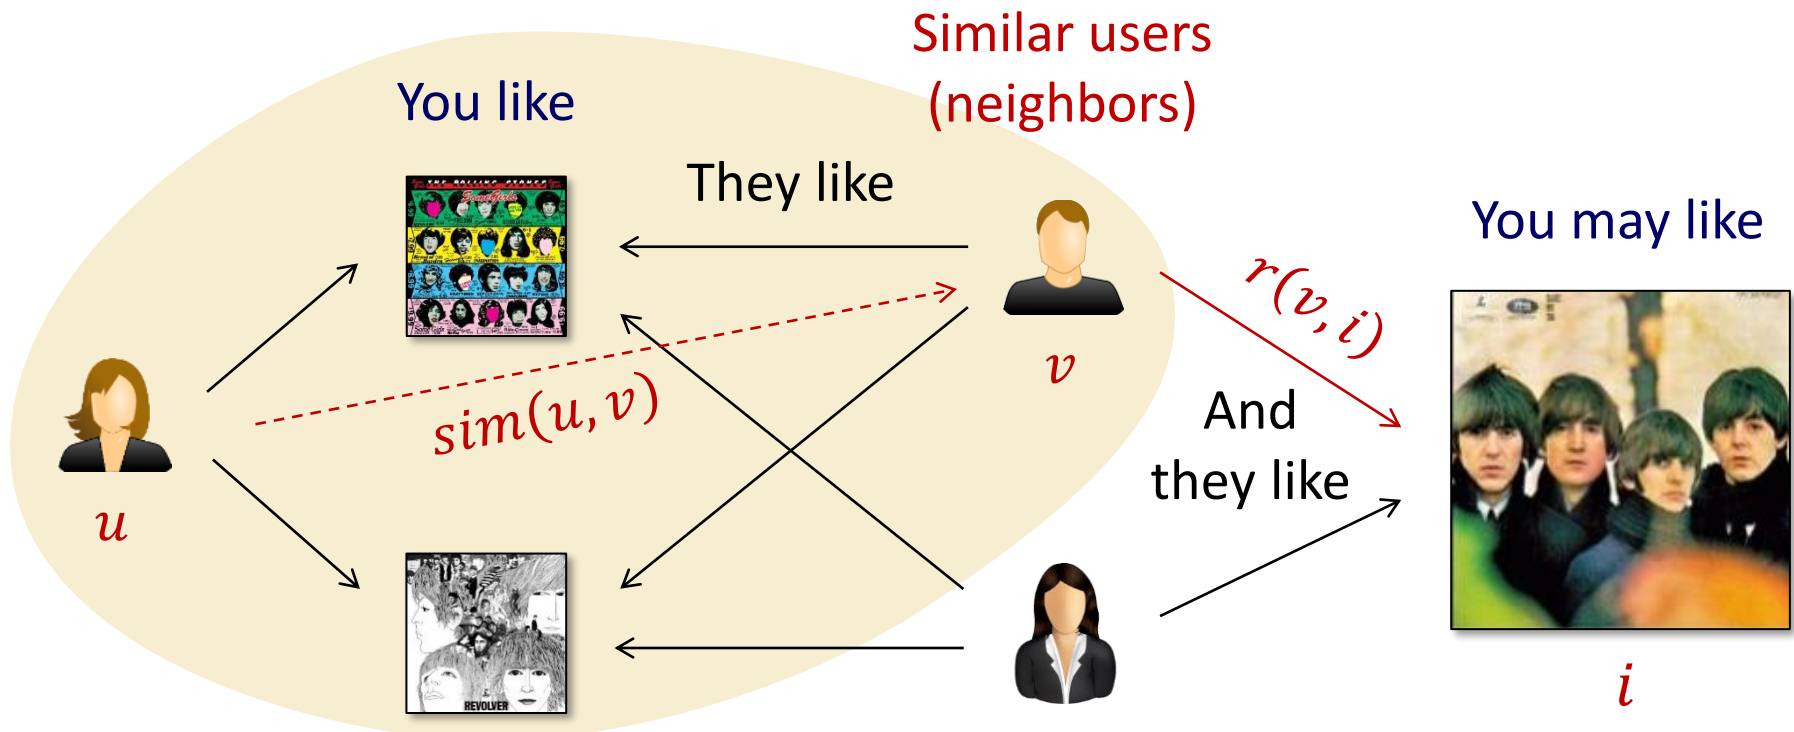
- ◆ Similar a kNN en clasificación
  - Pero a) la similitud entre ítems se basa siempre en ratings, y b) en las recomendaciones a un usuario intervienen ratings de otros usuarios
- ◆ Dos perspectivas (cuasi)simétricas
  - Basado en usuarios: el algoritmo recomienda al usuario los ítems que han gustado a usuarios parecidos
  - Basado en ítems: el sistema recomienda al usuario ítems que se parecen a ítems que le han gustado
- ◆ Se forma un vecindario de usuarios o de ítems
  - Top  $k$  más similares, o clustering, o todos
- ◆ Se computa una predicción de rating mediante combinación lineal del rating de los vecinos

# kNN colaborativo

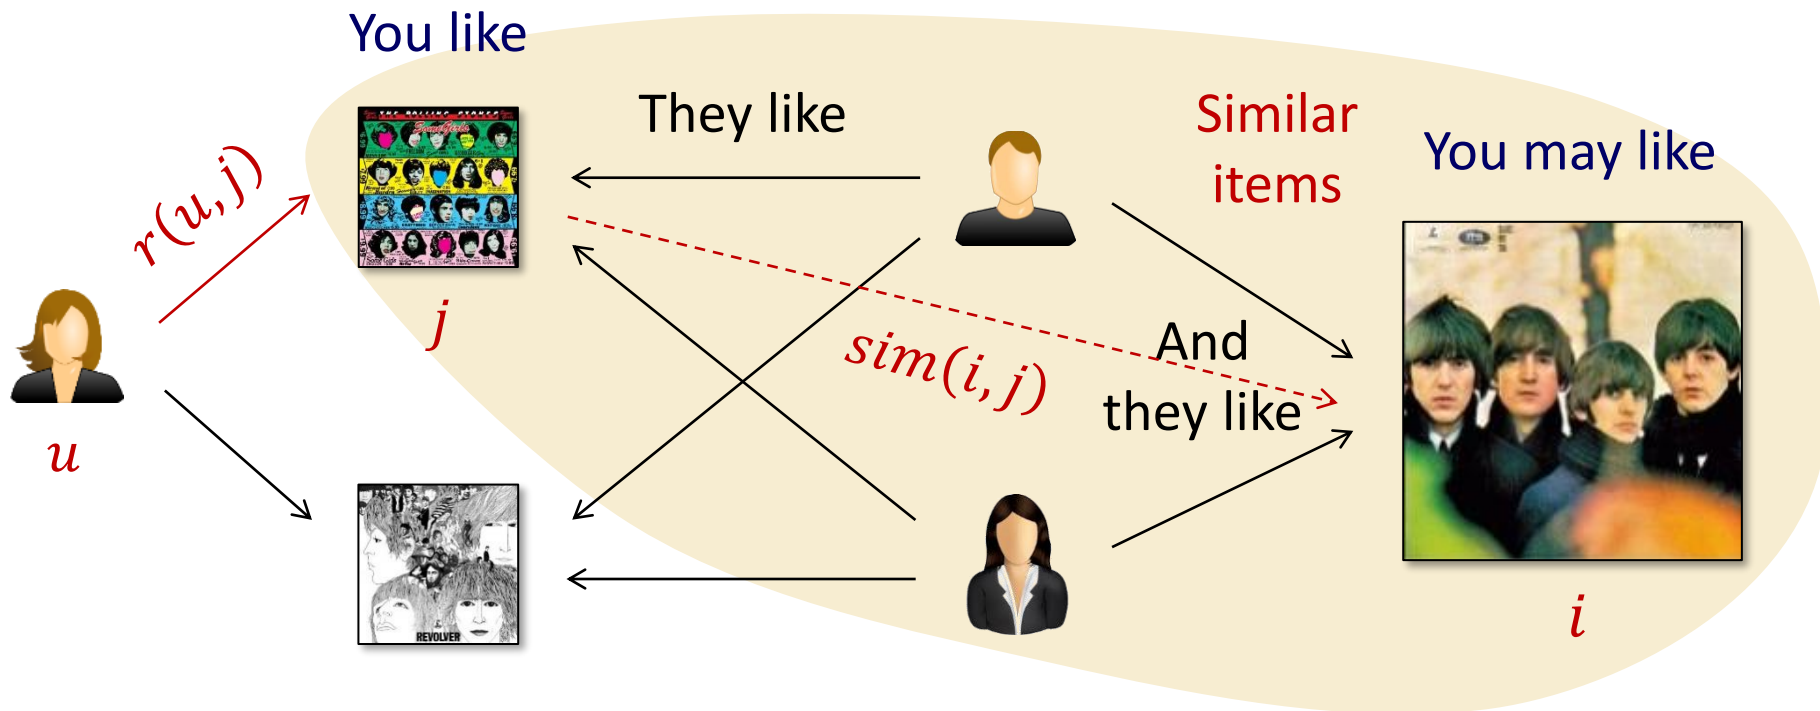




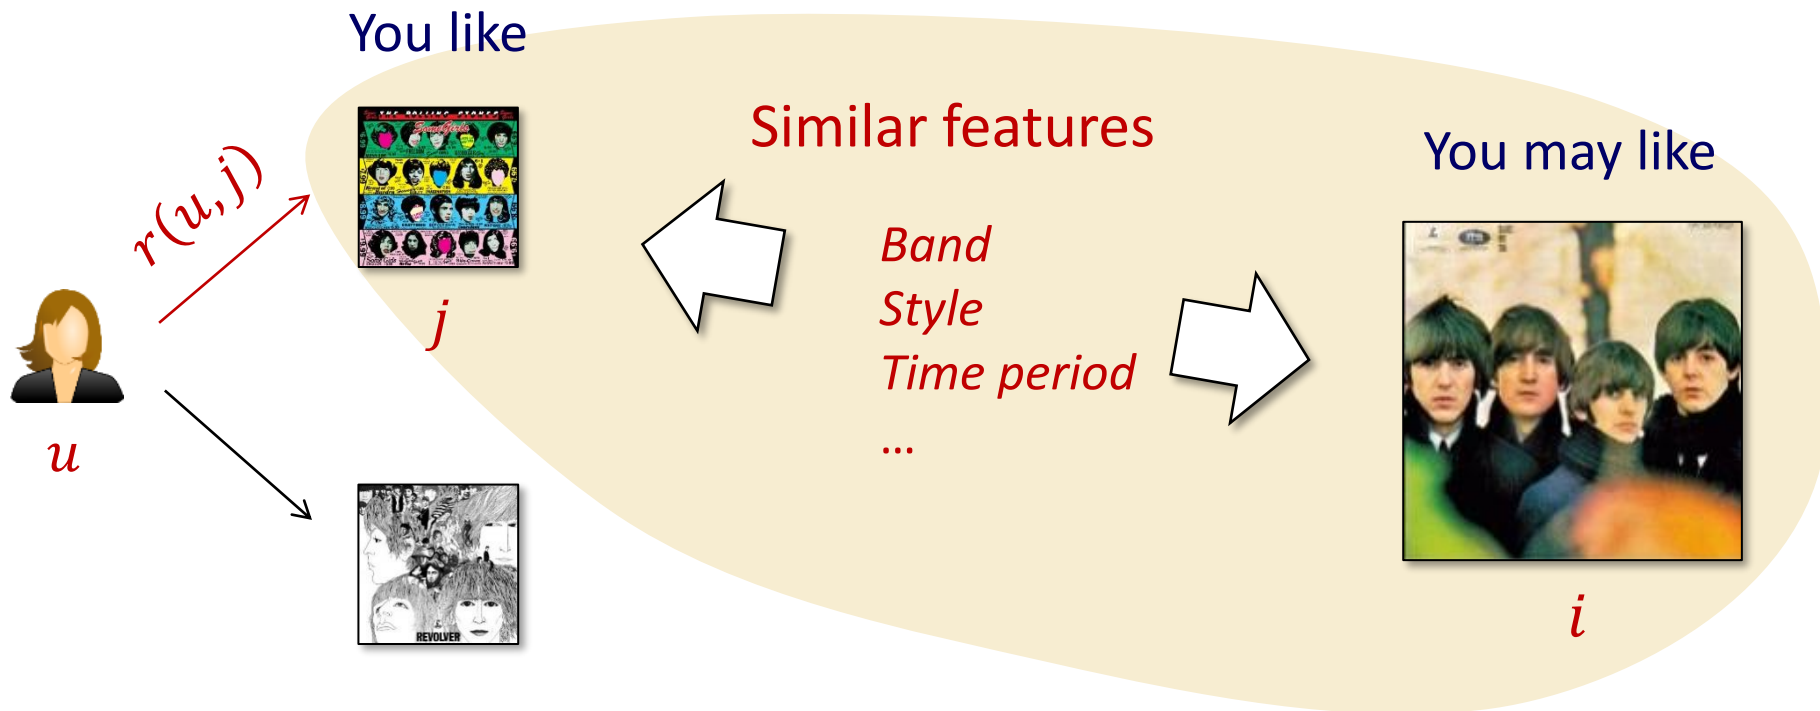
# kNN colaborativo: basado en usuario



# kNN colaborativo: basado en ítem



# kNN basado en contenido



# Predicción de ratings kNN

- ◆ Basado en usuario: Vecindario  $N_k(u) \equiv$  top  $k$  vecinos más similares a  $u$

$$\hat{r}(u, i) = C \sum_{\substack{v \in N_k(u) \\ r(v, i) \neq \emptyset}} sim(u, v) r(v, i)$$

Desconocido (a predecir)
Conocido
Necesario para ratings en rango

$$C = 1 / \sum_{\substack{v \in N_k(u) \\ r(v, i) \neq \emptyset}} |sim(u, v)|$$

- ◆ Basado en ítem:

$$\hat{r}(u, i) = C \sum_{r(u, j) \neq \emptyset} sim(i, j) r(u, j)$$

$$C = 1 / \sum_{r(u, j) \neq \emptyset} |sim(i, j)|$$

# Similitud entre usuarios

- ◆ Coseno

$$\text{sim}(u, v) = \sum_{\substack{i:r(u,i) \neq \emptyset \\ r(v,i) \neq \emptyset}} r(u,i)r(v,i) / \sqrt{\sum_{i:r(u,i) \neq \emptyset} r(u,i)^2 \sum_{i:r(v,i) \neq \emptyset} r(v,i)^2} \in [0,1]$$

- ◆ Correlación de Pearson

$$\text{sim}(u, v) = \sum_{\substack{i:r(u,i) \neq \emptyset \\ r(v,i) \neq \emptyset}} (r(u,i) - \bar{r}_u)(r(v,i) - \bar{r}_v) / \sqrt{\sum_{\substack{i:r(u,i) \neq \emptyset \\ r(v,i) \neq \emptyset}} (r(u,i) - \bar{r}_u)^2 \sum_{\substack{i:r(u,i) \neq \emptyset \\ r(v,i) \neq \emptyset}} (r(v,i) - \bar{r}_v)^2}$$

↑  
Puntuación  
promedio de  $u$



$\in [-1,1]$

- ◆ Similitudes basadas en datos personales (p.e. demográficos)

# Predicción de ratings kNN: variante centrada en la media

- ♦ Para compensar sesgos en la forma de puntuar de los usuarios, en la versión basada en usuario:

$$\hat{r}(u, i) = \bar{r}_u + C \sum_{\substack{v \in N_k(u) \\ r(v, i) \neq \emptyset}} \text{sim}(u, v)(r(v, i) - \bar{r}_v)$$

Puntuación promedio del usuario  $u$   

Puntuación promedio del vecino  $v$

(obsérvese que con esta fórmula podrían salir ratings fuera de rango)

# Similitud entre ítems

- ♦ Mismas funciones que para usuarios: Pearson, coseno...
  - Intercambiando simétricamente el papel de ítems y usuarios
- ♦ Se suele contemplar alguna variante más
  - P.e. coseno centrado en la media del usuario
- ♦ Si se utiliza similitud basada en contenido ya no es filtrado colaborativo, sino kNN basado en contenido
  - Por lo demás la estructura de kNN basado en ítem colaborativo y basado en contenido es la misma

# Otros detalles en el cálculo de similitud

- ♦ En Pearson la puntuación promedio  $\bar{r}_u, \bar{r}_i$  se podría tomar sobre todos los ratings del usuario/ítem, o ceñida al solapamiento
  - Es frecuente encontrar lo 2º, pero parece funcionar mejor lo 1º
- ♦ Con medidas como Pearson podrían salir ratings negativos
  - Pero es muy improbable salvo en ejemplos muy pequeños
- ♦ Se investigan muchas otras variantes de similitud, otras variantes de vecindario (p.e. clustering, vecindarios inversos), etc.



# Otros métodos de filtrado colaborativo

- ◆ Clustering para kNN
- ◆ Factorización de matrices
  - Obtener representación de usuarios e ítems  $u_f, i_f$  en un espacio de factores latentes  $f \in \mathcal{F}$
  - Minimizando  $\sum_{(u,i) \in training} \left[ (r(u,i) - \sum_f u_f i_f)^2 + \lambda (\sum_f u_f^2 + \sum_f i_f^2) \right]$   
(p.e. descenso por gradiente, mínimos cuadrados, etc.)
  - Finalmente  $\hat{r}(u,i) = \sum_f u_f i_f$
- ◆ Random walks
  - En el grafo bipartito de usuarios + ítems, donde los ratings se interpretan como arcos
- ◆ ...y muchos más

# Punto débil de FC: Data sparsity


- ♦ Hay usuarios e ítems que no son comparables entre sí
  - Cuando no tienen solapamiento
  - En ocasiones algún usuario (ítem) se queda sin vecinos, y por tanto sin recomendaciones (sin recomendar)
  - La similitud basada en solapamientos pequeños se puede usar, pero menos fiable cuanto menor el solapamiento: normalmente mín 2-3
- ♦ Los vecinos no siempre se pueden usar
  - Además de estar en el vecindario, tienen que haber puntuado el ítem cuyo rating queremos predecir (y lo equivalente en la versión ítem)  
Salvo que elijamos el vecindario distinto para cada ítem (asegurando  $k$  vecinos para cada ítem), pero es costoso y poco habitual seguir esta opción
  - La recomendación pierde fiabilidad cuando el vecindario efectivo es demasiado pequeño: p.e. mín 2-3 vecinos
- ♦ Estos problemas dominan en ítems nuevos / raros y usuarios nuevos / poco activos (arranque en frío)



# Valoración de filtrado colaborativo

- ♦ Puede funcionar con ítems totalmente opacos, sin ninguna descripción de los mismos más que los ratings asignados por usuarios
- ♦ Buenos niveles de acierto
  - Una de las opciones más eficaces suele ser la factorización de matrices
- ♦ Diversidad y novedad
  - Generalmente proporcionan más diversidad que la recomendación basada en contenido
  - Y más novedad respecto a la experiencia previa de los usuarios
- ♦ Su punto débil es el arranque en frío, los ítems poco conocidos y los usuarios poco activos: en definitiva la dispersión de ratings
  - Los usuarios poco activos son difíciles en igual medida para los métodos basados en contenido
  - La solución para estos casos es utilizar información estática del usuario: datos personales, cuestionarios, etc.
    - Para definir la similitud entre usuarios en filtrado colaborativo
    - Como características en clasificación o regresión basada en contenido

# Comparativa\*




\* Valores normalizados a [0.1,0.9] con min-max


# Recomendación basada en contenido

La intuición:


You like



Similar features



*Band*  
*Style*  
*Time period*  
...




You may like



# Recomendación basada en contenido

- ♦ Se recomienda a cada usuario **sin mirar a los demás**
- ♦ Se necesita un espacio de características de los ítems
  - “Datos” que describen los ítems, estructurados o no estructurados
  - P.e. metadatos del ítem (autor, lugar, idioma, categorías, etiquetas), palabras del texto asociado al ítem, etc.
  - Valores binarios, enteros, o reales
  - Los ítems se representan como vectores en este espacio
- ♦ Y una función de similitud en ese espacio
  - Por ejemplo, el coseno para características numéricas
  - O Jaccard para características binarias
- ♦ Dos métodos muy comunes: basado en centroides y kNN
  - Pero se pueden utilizar muchos otros basados en clasificación (donde los usuarios juegan en esencia el papel de clase)






# Recom. basada en contenido: centroides

Vectores: características numéricas

$C = 1/|u|$  (opcional, p.e. para distancia euclídea)


$$\text{Centroide } \vec{u} = C \sum_{j:r(u,j) \neq \emptyset} r(u,j) \cdot \vec{j}$$



Adaptación de clasificación Rocchio

- ◆ En clasificación sería  $r(u, j)$  binario
- ◆ Normalización por  $C$  (para coseno no hace falta)
- ◆ Y además hacemos ránking de “instancias” (ítems) para cada “clase” (usuario) en lugar de lo contrario

# Recom. basada en contenido: kNN



$$\hat{r}(u, i) = C \sum_{\substack{j \in N_k(i) \\ r(u, j) \neq \emptyset}} \text{sim}(i, j) r(u, j)$$

Función de ránking (y predicción de rating)

$$C = 1 / \sum_{\substack{j \in N_k(i) \\ r(u, j) \neq \emptyset}} |\text{sim}(i, j)|$$

Opcional: para predecir ratings en rango

## Adaptación de clasificación kNN

- ♦ En clasificación sería  $r(u, j)$  binario
- ♦ Y además hacemos ránking de “instancias” (ítems) para cada “clase” (usuario) en lugar de lo contrario
- ♦ También se puede entender (es más natural) como regresión kNN



# En resumen...

## ♦ Rocchio

$$u = C \sum_{j:r(u,j) \neq \emptyset} r(u,j) \cdot j$$

Función de ránking  $\swarrow$

Opcional p.e. para distancia euclídea  $\swarrow$

$$sim(u,i) = \cos(u,i)$$

$$C = 1/|u|$$

Generalización: originalmente sería  $r(u,j)$  binario

## ♦ kNN

$$\hat{r}(u,i) = C \sum_{\substack{j \in N_k(i) \\ r(u,j) \neq \emptyset}} sim(i,j) r(u,j)$$

Opcional: para predecir ratings en rango  $\swarrow$

$$C = 1 / \sum_{\substack{j \in N_k(i) \\ r(u,j) \neq \emptyset}} |sim(i,j)|$$

Función de ránking (y predicción de rating)  $\swarrow$

# Ejemplo

$f_1$	2	0	1.5	0.5	1	2.5	0	7.5	3.2	1
$f_2$	1	2	10	1	0	16	20	0	8	5
$f_3$	0	2	1	1	3	5	1	2	1	3
$f_4$	4	1	0	2	1	0	1	2	1	0

Matriz de  
características  
de ítems

	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$
$u_1$	1		4		5		2			5
$u_2$		2		3		3	5		1	
$u_3$	4				4		3			2
$u_4$		2	1	5			1	3		3
$u_5$	3		4		3	5			4	


Matriz de ratings  
usuario/ítem

# Rocchio – Centroides de usuarios

		$u_1$	$u_2$	$u_3$	$u_4$	$u_5$				
$f_1$	2	0	1.5	0.5	1	2.5	0	7.5	3.2	1
$f_2$	1	2	10	1	0	16	20	0	8	5
$f_3$	0	2	1	1	3	5	1	2	1	3
$f_4$	4	1	0	2	1	0	1	2	1	0
	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$
$u_1$	1		4		5		2			5
$u_2$		2		3		3	5		1	
$u_3$	4				4		3			2
$u_4$		2	1	5			1	3		3
$u_5$	3		4		3	5			4	


  

$u_1$	$u_2$	$u_3$	$u_4$	$u_5$
3.6	2.4	3.5	4.9	8.1
21.2	32.6	18.5	9.0	31.0
7.2	5.6	5.3	4.3	8.4
2.2	2.8	5.8	3.2	3.8

  
 Centroides de usuarios

$$\text{P.e. } u_1[f_1] = \frac{1 \cdot 2 + 4 \cdot 1.5 + 5 \cdot 1 + 2 \cdot 0 + 5 \cdot 1}{5} = 3.6$$

# Rocchio – Centroides de usuarios



# Rocchio – Similitud con centroides

												$u_1$	$u_2$	$u_3$	$u_4$	$u_5$
$f_1$	2	0	1.5	0.5	1	2.5	0	7.5	3.2	1		3.6	2.4	3.5	4.9	8.1
$f_2$	1	2	10	1	0	16	20	0	8	5		21.2	32.6	18.5	9.0	31.0
$f_3$	0	2	1	1	3	5	1	2	1	3		7.2	5.6	5.3	4.3	8.4
$f_4$	4	1	0	2	1	0	1	2	1	0		2.2	2.8	5.8	3.2	3.8
	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$						
$u_1$	1	0.86	4	0.61	5	0.99	2	0.25	0.96	5						
$u_2$	0.32	2	0.99	3	0.20	3	5	0.13	1	0.93						
$u_3$	4	0.87	0.94	0.73	4	0.96	3	0.30	0.96	2						
$u_4$	0.59	2	1	5	0.55	0.91	1	3	0.94	3						
$u_5$	3	0.83	4	0.61	3	5	0.95	0.32	4	0.95						

$$\text{P. e. } \text{sim}(u_1, i_2) = \frac{3.6 \cdot 0 + 21.2 \cdot 2 + 7.2 \cdot 2 + 2.2 \cdot 1}{\sqrt{3.6^2 + 21.2^2 + 7.2^2 + 2.2^2} \sqrt{0^2 + 2^2 + 2^2 + 1^2}} = 0.86$$

# kNN – Similitud entre ítems (contenido)

$f_1$	2	0	1.5	0.5	1	2.5	0	7.5	3.2	1
$f_2$	1	2	10	1	0	16	20	0	8	5
$f_3$	0	2	1	1	3	5	1	2	1	3
$f_4$	4	1	0	2	1	0	1	2	1	0
	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$

$i_1$	1									
$i_2$	0.44	1								
$i_3$	0.28	0.72	1							
$i_4$	0.87	0.80	0.46	1						
$i_5$	0.39	0.70	0.13	0.66	1					
$i_6$	0.27	0.83	0.98	0.53	0.31	1				
$i_7$	0.26	0.71	0.99	0.46	0.06	0.96	1			
$i_8$	0.63	0.25	0.16	0.49	0.58	0.21	0.02	1		
$i_9$	0.46	0.73	0.97	0.58	0.25	0.95	0.93	0.40	1	
$i_{10}$	0.26	0.90	0.91	0.57	0.51	0.97	0.87	0.28	0.89	1

$$\text{P. e. } \text{sim}(i_1, i_2) = \frac{2 \cdot 0 + 1 \cdot 2 + 0 \cdot 2 + 4 \cdot 1}{\sqrt{2^2 + 1^2 + 0^2 + 4^2} \sqrt{0^2 + 2^2 + 2^2 + 1^2}} = 0.44$$

# kNN – Estimación de ratings ( $k \geq 9$ )

$u_1$	1	3.67	4	3.24	5	3.59	2	3.37	3.40	5
$u_2$	2.64	2	2.83	3	2.46	3	5	2.27	1	1.89
$u_3$	4	3.09	2.79	3.37	4	2.84	3	3.61	2.93	2
$u_4$	3.08	2	1	5	3.09	2.18	1	3	2.25	3
$u_5$	3	3.91	4	3.67	3	5	4.20	3.50	4	4.06

	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$
$i_1$	1	0.44	0.28	0.87	0.39	0.27	0.26	0.63	0.46	0.26
$i_2$	0.44	1	0.72	0.80	0.70	0.83	0.71	0.25	0.73	0.90
$i_3$	0.28	0.72	1	0.46	0.13	0.98	0.99	0.16	0.97	0.91
$i_4$	0.87	0.80	0.46	1	0.66	0.53	0.46	0.49	0.58	0.57
$i_5$	0.39	0.70	0.13	0.66	1	0.31	0.06	0.58	0.25	0.51
$i_6$	0.27	0.83	0.98	0.53	0.31	1	0.96	0.21	0.95	0.97
$i_7$	0.26	0.71	0.99	0.46	0.06	0.96	1	0.02	0.93	0.87
$i_8$	0.63	0.25	0.16	0.49	0.58	0.21	0.02	1	0.40	0.28
$i_9$	0.46	0.73	0.97	0.58	0.25	0.95	0.93	0.40	1	0.89
$i_{10}$	0.26	0.90	0.91	0.57	0.51	0.97	0.87	0.28	0.89	1

# kNN – Estimación de ratings ( $k \geq 9$ )

$u_1$	1	3.67	4	3.24	5	3.59	2	3.37	3.40	5
$u_2$	2.64	2	2.83	3	2.46	3	5	2.27	1	1.89
$u_3$	4	3.09	2.79	3.37	4	2.84	3	3.61	2.93	2
$u_4$	3.08	2	1	5	3.09	2.18	1	3	2.25	3
$u_5$	3	3.91	4	3.67	3	5	4.20	3.50	4	4.06
	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$

$i_1$	1	0.44	0.28	0.87	0.39	0.27	0.26	0.63	0.46	0.26
$i_2$	0.44	1	0.72	0.80	0.70	0.83	0.71	0.25	0.73	0.90
$i_3$	0.28	0.72	1	0.46	0.13	0.98	0.99	0.16	0.97	0.91
$i_4$	0.87	0.80	0.46	1	0.66	0.53	0.46	0.49	0.58	0.57

P. e.  $\hat{r}(u_1, i_2) = \frac{0.44 \cdot 1 + 0.72 \cdot 4 + 0.7 \cdot 5 + 0.71 \cdot 2 + 0.9 \cdot 5}{0.44 + 0.72 + 0.7 + 0.71 + 0.9} = 3.67$

$i_5$	0.39	0.70	0.13	0.66	1	0.06	0.21	0.25	0.51	0.97
$i_6$	0.27	0.83	0.98	0.53	0.98	1	0.02	0.95	0.87	0.87
$i_7$	0.26	0.71	0.99	0.46	0.06	0.96	1	0.02	0.93	0.87
$i_8$	0.63	0.25	0.16	0.49	0.58	0.21	0.02	1	0.40	0.28
$i_9$	0.46	0.73	0.97	0.58	0.25	0.95	0.93	0.40	1	0.89
$i_{10}$	0.26	0.90	0.91	0.57	0.51	0.97	0.87	0.28	0.89	1



# kNN – Estimación de ratings (p.e. $k = 5$ )

$u_1$	1		4		5		2		5
$u_2$		2		3		3	5		1
$u_3$	4				4		3		2
$u_4$		2	1	5			1	3	3
$u_5$	3		4		3	5		4	

	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$
$i_1$	1	0.44	0.28	0.87	0.39	0.27	0.26	0.63	0.46	0.26
$i_2$	0.44	1	0.72	0.80	0.70	0.83	0.71	0.25	0.73	0.90
$i_3$	0.28	0.72	1	0.46	0.13	0.98	0.99	0.16	0.97	0.91
$i_4$	0.87	0.80	0.46	1	0.66	0.53	0.46	0.49	0.58	0.57
$i_5$	0.39	0.70	0.13	0.66	1	0.31	0.06	0.58	0.25	0.51
$i_6$	0.27	0.83	0.98	0.53	0.31	1	0.96	0.21	0.95	0.97
$i_7$	0.26	0.71	0.99	0.46	0.06	0.96	1	0.02	0.93	0.87
$i_8$	0.63	0.25	0.16	0.49	0.58	0.21	0.02	1	0.40	0.28
$i_9$	0.46	0.73	0.97	0.58	0.25	0.95	0.93	0.40	1	0.89
$i_{10}$	0.26	0.90	0.91	0.57	0.51	0.97	0.87	0.28	0.89	1

Vecindario por filas

# kNN – Estimación de ratings ( $k = 5$ )

$u_1$	1		4		5		2		5
$u_2$		2		3		3	5	1	
$u_3$	4				4		3		2
$u_4$		2	1	5			1	3	3
$u_5$	3		4		3	5		4	

	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$
$i_1$		0.44		0.87	0.39			0.63	0.46	
$i_2$			0.72	0.80		0.83			0.73	0.90
$i_3$		0.72				0.98	0.99		0.97	0.91
$i_4$	0.87	0.80			0.66				0.58	0.57
$i_5$	0.39	0.70		0.66				0.58		0.51
$i_6$		0.83	0.98				0.96		0.95	0.97
$i_7$		0.71	0.99			0.96			0.93	0.87
$i_8$	0.63			0.49	0.58				0.40	0.28
$i_9$		0.73	0.97			0.95	0.93			0.89
$i_{10}$		0.90	0.91			0.97	0.87		0.89	

# kNN – Estimación de ratings ( $k = 5$ )

$u_1$	1	4.56	4	3.35	5	3.68	2	3.32	3.66	5
$u_2$	2.23	2	2.81	3	2.49	3	5	2.10	1	2.19
$u_3$	4	0.85	1.05	2.09	4	1.03	3	2.27	1.27	2
$u_4$	3.68	2	1	5	3.25	1.74	1	3	1.72	3
$u_5$	3	3.41	4	3.27	3	5	4.33	3.25	4	4.35

$$\text{P. e. } \hat{r}(u_1, i_2) = \frac{0.72 \cdot 4 + 0.9 \cdot 5}{0.72 + 0.9} = 4.56$$

	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$
$i_1$		0.44		0.87	0.39			0.63	0.46	
$i_2$			0.72	0.80		0.83			0.73	0.90
$i_3$		0.72				0.98	0.99		0.97	0.91
$i_4$	0.87	0.80			0.66				0.58	0.57
$i_5$	0.39	0.70		0.66				0.58		0.51
$i_6$		0.83	0.98				0.96		0.95	0.97
$i_7$		0.71	0.99			0.96			0.93	0.87
$i_8$	0.63			0.49	0.58				0.40	0.28
$i_9$		0.73	0.97			0.95	0.93			0.89
$i_{10}$		0.90	0.91			0.97	0.87		0.89	

# kNN – Estimación de ratings ( $k = 5$ )

$u_1$	1	4.56	4	3.35	5	3.68	2	3.32	3.66	5
$u_2$	2.23	2	2.81	3	2.49	3	5	2.10	1	2.19
$u_3$	4	0.85	1.05	2.09	4	1.03	3	2.27	1.27	2
$u_4$	3.68	2	1	5	3.25	1.74	1	3.77	3	3.41
$u_5$	3	3.41	4	3.27	3	5	4.33	3.25	4	4.35

	$i_1$	$i_2$	$i_3$	$i_4$	$i_5$	$i_6$	$i_7$	$i_8$	$i_9$	$i_{10}$
$i_1$		0.44		0.87	0.39			0.63	0.46	
$i_2$			0.72	0.80		0.83			0.73	0.90
$i_3$		0.72				0.98	0.99		0.97	0.91
$i_4$	0.87	0.80			0.66				0.58	0.57
$i_5$	0.39	0.70		0.66				0.58		0.51
$i_6$		0.83	0.98				0.96		0.95	0.97
$i_7$		0.71	0.99			0.96			0.93	0.87
$i_8$	0.63			0.49	0.58				0.40	0.28
$i_9$		0.73	0.97			0.95	0.93			0.89
$i_{10}$		0.90	0.91			0.97	0.87		0.89	

$$Predict(u_1, i_2) = \frac{0.72 \cdot 4 + 0.9 \cdot 5}{0.72 + 0.9} = 4.56$$

# Otros métodos basados en contenido

- ♦ Cualquier método de clasificación / regresión sería potencialmente válido

- ♦ P.e. Naïve Bayes

$$p(r|u, i) = \frac{p(i|r, u)p(r|u)}{\sum_{r'} p(i|r', u)p(r'|u)} \quad p(i|r, u) \sim \prod_l p(i_f|r, u)$$

Se estima como en clasificación (Bernoulli / multinomial / gaussiano)

$i_f \equiv$  características de  $i$  (texto, etc.)

$$\hat{r}(u, i) = \mathbb{E}[r|u, i] = \sum_r r \cdot p(r|u, i)$$

Función de ránking (y predicción de rating)      **Nuevo:** al ser clases numéricas tiene sentido la esperanza

En lugar de  $class(i) = \arg \max_u f(u, i)$  usamos  $f(u, i)$  como función de ránking para recomendar ítems a  $u$

# Recomendación basada en contenido: valoración

- ♦ Capaz de recomendar ítems que no tienen ratings
  - Permite recomendar ítems nuevos y/o poco conocidos
  - No sirve en general para usuarios nuevos y/o poco activos (salvo NB o regresión usando otras características, datos o input de los usuarios)
- ♦ Aunque tiene un efecto de “encasillamiento” del usuario
  - Lo que se recomienda se parece a lo que el usuario ya ha visto
- ♦ Es un buen complemento de los métodos colaborativos en soluciones híbridas

# Evaluación

## ♦ Metodología

- Como en clasificación, separar ratings en entrenamiento y test (p.e. 80-20%)
- Predecir ratings de test usando training y medir el nivel de acierto
- Si el split es aleatorio, repetir  $n$ -fold (p.e. 5-fold para 80-20%)
- También se utiliza split temporal, más realista respecto a un escenario natural

## ♦ Las métricas clásicas miden el **error de predicción**



$$\left. \begin{aligned} MAE &= \frac{1}{|test|} \sum_{(u,i) \in test} |\hat{r}(u,i) - r(u,i)| \\ RMSE &= \sqrt{\frac{1}{|test|} \sum_{(u,i) \in test} (\hat{r}(u,i) - r(u,i))^2} \end{aligned} \right\} 0 \leq MAE \leq RMSE \leq \max(r)$$

# Evaluación

- ♦ El error de predicción no es la mejor métrica (evalúa regresión)
  - Correlaciona poco con la satisfacción del usuario en la práctica
  - Además, no se puede calcular el error para los métodos que no predicen ratings
- ♦ También se utilizan la curva ROC y el área bajo la curva (AUC) (evalúan clasificación)
- ♦ En general tienen más sentido **métricas de ránking**: todas las de IR ( $P@k$ , nDCG, MAP, etc.), usando los ratings de test como juicios de relevancia
- ♦ Métricas para otras dimensiones, p.e. novedad y diversidad
- ♦ En la industria: **tests A/B**




# Ejemplo

	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>	<i>e</i>	<i>f</i>	<i>g</i>	<i>h</i>
$u_1$ 	4	5			5	2		4
$u_2$ 			1	1		4	5	4

# Ejemplo

Score del  
recomendador

Rating  
de test


		
$u_1$	$\hat{r}(u_1, i)$	$r(u_1, i)$
$a$	5	4
$b$	5	5
$c$	4	
$d$	4	
$e$	4	5

$$P@1 = \frac{1/1 + 0/1}{2}$$

$$P@2 = \frac{2/2 + 0/2}{2}$$

$$P@3 = \frac{2/3 + 1/3}{2}$$

etc.

		
$u_2$	$\hat{r}(u_1, i)$	$r(u_1, i)$
$e$	5	
$b$	5	
$f$	5	4
$d$	5	1
$a$	4	

$$\text{Recall}@1 = \frac{1/4 + 0/2}{2}$$

$$\text{Recall}@2 = \frac{2/4 + 0/2}{2}$$




$$\text{Recall}@3 = \frac{2/4 + 1/2}{2}$$

etc.

$u_1$  

$u_2$  

	$a$	$b$	$c$	$d$	$e$	$f$	$g$	$h$
$u_1$	4	5			5	2		4
$u_2$			1	1		4	5	4

	Test		Training
	Desconocido		

“Relevante”  
“No relevante”

P.e. umbral de relevancia = 4

$$\text{RMSE} = \sqrt{[(5 - 4)^2 + (5 - 5)^2 + (4 - 5)^2 + (5 - 4)^2 + (5 - 1)^2]/5}$$

# Recomendación vs. búsqueda

- ♦ Equivalencia con una tarea de búsqueda
  - El perfil de usuario juega el papel de consulta, y los ítems el de documentos
  - La consulta es implícita: histórico de interacciones (ratings) del usuario con ítems
  - La tarea es devolver un ránking de ítems para cada usuario
- ♦ En recomendación BC hay analogías también en los métodos
  - El usuario se puede representar como un vector (p.e. Rocchio), un modelo probabilístico, etc.
  - También es posible obtener un vector de usuario sin usar ratings, p.e. tags acumulados que el usuario ha asignado a ítems
  - Se hace un ránking de ítems por similitud con el perfil: coseno en el VSM, otras funciones de ránking para otros modelos
  - Según el espacio de características se pueden contemplar otras similitudes: producto escalar, Jaccard (para binarias), etc.

# Recomendación vs. clasificación

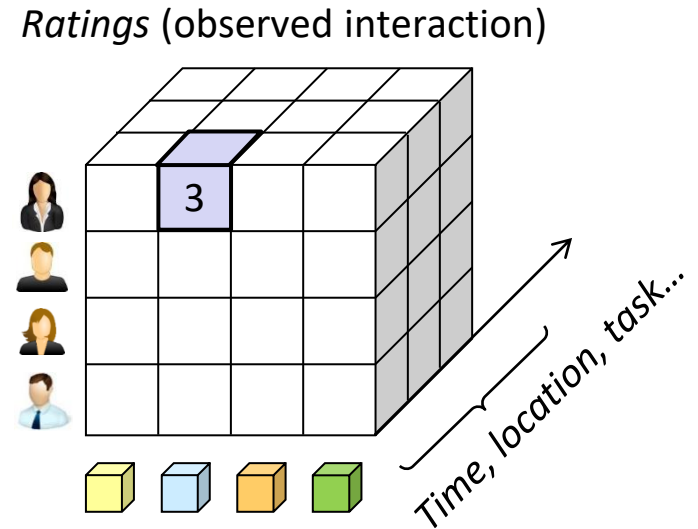
- ♦ La recomendación se puede también ver como una tarea de clasificación
  - Multiclase: usuarios  $\equiv$  clases (la de los ítems que gustan a cada usuario), ítems  $\equiv$  patrones
  - O clasificación binaria de pares usuario / ítem en clases “gusta” o “no gusta”
  - Los ratings observados forman el conjunto de ejemplos
  - Los ítems con los que el usuario no ha interactuado (conjunto de test) son a clasificar
- ♦ Cuando la relación usuario/ítem no es binaria hay que **variar la formulación**
  - En Rocchio y kNN p.e. usar ratings como pesos (en cómputo de centroide y suma de similitudes)
  - En Naïve Bayes p.e. clases  $\equiv$  valores de rating, clasificar pares usuario/ítem (aunque suele ser más natural utilizar regresión, tratando los ratings como función real sobre usuarios  $\times$  ítems)
- ♦ Interesa generar un **ránking de ítems** por usuario (clase) más que lo inverso
  - Puesto que ése es el output ordenado a presentar al usuario
  - El ránking es además fundamental pues el usuario no va a mirar todos los ítems que se le podrían recomendar

# Últimos avances / problemas abiertos

- ◆ Escalabilidad
  - Optimizaciones en la implementación, paralelización
  - Cálculos offline (p.e. similitudes: guardar en disco, cache, etc.)
  - Actualización incremental
  - En general se consigue funcionar con muchos menos recursos que p.e. un buscador Web
- ◆ Arranque en frío
- ◆ Feedback negativo
- ◆ Actualización al vuelo
  - La personalización más plena requiere un espacio de tiempo offline
- ◆ Explicación
- ◆ Manipulación


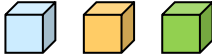











# Últimos avances / problemas abiertos

- ◆ Recomendación contextual
  - Tarea, hora/fecha, localización, estado de ánimo, etc.
- ◆ Novedad y diversidad
  - No sólo acierto
  - Algoritmos, métricas, diferentes nociones de novedad y diversidad
- ◆ Evaluación en general, sesgos, valor para proveedor, mediador, etc.
- ◆ Métodos: factorización de matrices, LTR, deep learning...
- ◆ Redes sociales



# Recomendación en redes sociales

- ♦ Se pueden recomendar más cosas (contactos, etiquetas, etc.)
- ♦ Se puede usar más evidencia para deducir posibles intereses

	Usuarios	Ítems	Etiquetas	...
				
	Red social	Ratings	Uso	
				
				
		P.e. links	Asignación	
				
				
			Relación semántica	
				
				

# Precauciones con la personalización

- ◆ Dificultad intrínseca de la tarea
  - Los gustos de los usuarios son variados, cambiantes (contextuales), contradictorios, la observación disponible es ambigua y parcial
  - Hay que ser realistas con el ratio de acierto esperable: personalización prudente
- ◆ Intrusividad, pérdida de control para el usuario
  - El sistema es “demasiado inteligente”, anticipa cuando no debe
  - Dar control al usuario (p.e. desactivar cuando quiera), personalización prudente, etc.
- ◆ Privacidad
  - El usuario debe estar informado de la monitorización y tener control sobre ella
- ◆ El efecto “filter bubble”
  - La personalización podría empobrecer la experiencia del usuario a largo plazo
  - Compatibilizar la personalización con la diversidad y la novedad



<http://aminotes.tumblr.com/post/5877998600/the-filter-bubble-eli-pariser-on-what-the>



# Precauciones con la personalización

- ♦ Sesgos, discriminación
  - Problema similar al que se da en aprendizaje automático (fairness)
  - Sesgo hacia recomendar ciertos productos (injusto para el vendedor)
  - Pueden perpetuarse sesgos de observaciones pasadas (p.e. sesgo de género en recomendación de candidatos para un puesto de trabajo)
- ♦ Valor para el usuario vs. reacción del usuario
  - Qué ganamos realmente con una recomendación
  - Puede no ser fácil distinguir valor con compulsividad
  - Promoción de polarización, adicción, etc.