

1. En medicina, se denomina prevalencia de una enfermedad a la probabilidad prior de que un sujeto esté enfermo. Se denomina sensibilidad de una prueba o test a la probabilidad de que dicho test resulte positivo cuando el sujeto está realmente enfermo. Se llama especificidad a la probabilidad de que el test resulte negativo para un paciente sano.


Considera una enfermedad con una prevalencia de 1 por cada 100 habitantes y un test para diagnosticarla con una sensibilidad del 95% y una especificidad del 90%.

- ¿Cuál es la probabilidad de que un paciente que ha dado positivo en el test esté en realidad sano (falso positivo)?
 - Si un sujeto ha dado positivo para el test diagnóstico y nos piden maximizar la verosimilitud, ¿qué diagnóstico deberíamos emitir?
 - ¿Y si nos piden maximizar la probabilidad a posteriori?
2. Considera el siguiente cuadro que representa las respuestas de 9 pacientes a 4 preguntas (A, B, C y D) cuyas posibles respuestas son sí/no. La última columna representa si el paciente ha desarrollado osteoporosis posteriormente.

Paciente	A	B	C	D	Desarrollo posterior de osteoporosis
1	Sí	Sí	No	Sí	Sí
2	No	Sí	Sí	No	Sí
3	No	No	No	Sí	No
4	Sí	Sí	No	Sí	Sí
5	Sí	No	Sí	Sí	No
6	No	Sí	No	No	Sí
7	Sí	Sí	Sí	No	No
8	Sí	No	Sí	Sí	No
9	Sí	Sí	Sí	Sí	Sí

- Según el método de Bayes, ¿cuál es la probabilidad de desarrollo de osteoporosis de un paciente que responde afirmativamente a las preguntas A y C?
- ¿Y según el método Naïve Bayes?
- ¿Cómo clasificaría el método K-NN un paciente que responda A=No, B=No, C=Sí, D=Sí considerando $k=3$? ¿Y $k=5$? Para resolver esta cuestión, considera que se utiliza, para todos los atributos, la codificación Sí=1 y No=0

3. Considera el siguiente problema de clasificación, donde tenemos dos clases (+, -) y los atributos numéricos N_1 y N_2 :



Queremos desarrollar un modelo de clasificación con el algoritmo C4.5. Sabiendo que la pregunta que selecciona dicho algoritmo para el nodo raíz es $N_1 > 6$, ¿cuál será el árbol final que se generará sin aplicar poda?

4. Considera una neurona artificial con función de activación escalón caracterizada por los parámetros $w_1 = 1.2$, $w_2 = -0.7$, $\theta = 0.3$. Clasifica mediante esta neurona los siguientes ejemplos:

$$\mathbf{x}_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{x}_4 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

5. Aplica regresión logística al problema AND (las entradas son x_1 , x_2 , que pueden adquirir los valores 0 y 1; la clase 1 corresponde a la salida 1 del AND). Utiliza aprendizaje online y la constante de aprendizaje $\eta = 1$. Supón que los pesos tienen un valor inicial $w_0 = -0.3$, $w_1 = 0$, $w_2 = 0.4$. Muestra los resultados del aprendizaje al cabo de la primera época, suponiendo que los patrones se muestran en el orden en el que aparecen en la tabla.

$\mathbf{x}^{(0)}$	$\mathbf{x}^{(1)}$	$\mathbf{x}^{(2)}$	t	w_0	w_1	w_2	h	$h-t$	Δw_0	Δw_1	Δw_2
1	0	0	0	-0.3	0	0.4	0.43	0.43	-0.43	0	0
1	1	0	0	-0.73	0	0.4	0.33	0.33	-0.33	-0.33	0
1	0	1	0	-1.05	-0.33	0.4	...				
1	1	1	1								

1. Solución:

Notación: H = enfermo.

- $P(H) = 1/100 = 0.01$
 $P(\text{positivo} | H) = 0.95$
 $P(\neg\text{positivo} | \neg H) = 0.90$

$$P(H | \text{positivo}) = 0.95 \cdot 0.01 / (0.95 \cdot 0.01 + (1-0.90) \cdot (1-0.01)) = 0.09$$

$$P(\neg H | \text{positivo}) = 1 - P(H | \text{positivo}) = 0.81$$

- $P(\text{positivo} | H) = 0.95$.
 $P(\text{positivo} | \neg H) = 1 - P(\neg\text{positivo} | \neg H) = 1 - 0.9 = 0.1$
ML elige entonces el diagnóstico H (es decir, enfermo)

- Como vimos en la primera respuesta, $P(H | \text{positivo}) = 0.09$.
Por tanto, $P(\neg H | \text{positivo}) = 1 - 0.09 = 0.91$.
Luego MAP elige el diagnóstico $\neg H$ (es decir, no enfermo)

2. Solución:

- $P(\text{osteoporosis} | A \wedge C) = \#(\text{ost} \wedge A \wedge C) / (\# A \wedge C) = 1/4 = 0.25$
- Según el método de Naïve Bayes,
 $P(A \wedge C \wedge \text{ost}) \sim P(A | \text{ost}) \cdot P(C | \text{ost}) \cdot P(\text{ost}) =$
 $[\#(A \wedge \text{ost}) / \# \text{ost}] \cdot [\#(C \wedge \text{ost}) / \# \text{ost}] \cdot [\# \text{ost} / N] = 3 \cdot 2 / 5 / 9 = 0.1333$

$$P(A \wedge C \wedge \neg \text{ost}) \sim P(A | \neg \text{ost}) \cdot P(C | \neg \text{ost}) \cdot P(\neg \text{ost}) =$$

$$[\#(A \wedge \neg \text{ost}) / \# \neg \text{ost}] \cdot [\#(C \wedge \neg \text{ost}) / \# \neg \text{ost}] \cdot [\# \neg \text{ost} / N] = 3 \cdot 3 / 4 / 9 = 0.25$$

Luego según Naïve Bayes, $P(A \wedge C | \text{ost}) \sim 0.1333 / (0.1333 + 0.25) = 0.35$

- Xtest: (0, 0, 1, 1)

Paciente	A	B	C	D	Clase	distancia ² con Xtest
1	1	1	0	1	Sí	3
2	0	1	1	0	Sí	2
3	0	0	0	1	No	1
4	1	1	0	1	Sí	3
5	1	0	1	1	No	1
6	0	1	0	0	Sí	3
7	1	1	1	0	No	3
8	1	0	1	1	No	1
9	1	1	1	1	Sí	2
Xtest	0	0	1	1		


Los 3 vecinos más próximos son los pacientes 3, 5 y 8 (los 3 con clase No), con lo cual se predice No.

Los 5 vecinos más próximos son los pacientes 3, 5, 8, 2 y 9 (3 No, 2 Sí), con lo cual se predice No.

3. Solución:

Aunque en el enunciado se daba la primera pregunta que realiza el árbol y no era necesario demostrar que $N_1 > 6$ es la pregunta que C4.5 realiza en el primer nodo, se incluye aquí esta demostración con fines didácticos:

¿Qué árbol desarrollaría C4.5 con los siguientes datos?



Solución:

Primero vamos a ver qué pregunta elegiría para la raíz.

La entropía de la clase es, ya que hay 8+ y 8-, $H(8/16, 8/16) = 1$ bits.

Las posibles preguntas con N_1 son:

Pregunta	Rama "No"	Rama "Sí"	Entropía clase en Rama "No"	Entropía clase en Rama "Sí"	$H(\text{clase} \mid \text{Pregunta})$	IG
$N_1 > 1$	2+, 1-	6+, 7-	$H(2/3, 1/3) = 0.918$ bits	$H(6/13, 7/13) = 0.996$ bits	$3/16 * 0.918 + 13/16 * 0.996 = 0.981$ bits	$1 - 0.981 = 0.019$ bits
$N_1 > 2$	3+, 2-	5+, 6-	$H(3/5, 2/5) = 0.971$ bits	$H(5/11, 6/11) = 0.994$ bits	$5/16 * 0.971 + 11/16 * 0.994 = 0.987$ bits	$1 - 0.987 = 0.013$ bits
$N_1 > 3$	3+, 4-	5+, 4-	$H(3/7, 4/7) = 0.985$ bits	$H(5/9, 4/9) = 0.991$ bits	$7/16 * 0.985 + 9/16 * 0.991 = 0.988$ bits	$1 - 0.988 = 0.012$ bits
$N_1 > 4$	3+, 5-	5+, 3-	$H(3/8, 5/8) = 0.954$ bits	$H(5/8, 3/8) = 0.954$ bits	$8/16 * 0.954 + 8/16 * 0.954 = 0.954$ bits	$1 - 0.954 = 0.046$ bits
$N_1 > 5$	3+, 6-	5+, 2-	$H(3/9, 6/9) = 0.918$ bits	$H(5/7, 2/7) = 0.863$ bits	$9/16 * 0.918 + 7/16 * 0.863 = 0.894$ bits	$1 - 0.894 = 0.106$ bits
$N_1 > 6$	4+, 7-	4+, 1-	$H(4/11, 7/11) = 0.946$ bits	$H(4/5, 1/5) = 0.722$ bits	$11/16 * 0.946 + 5/16 * 0.722 = 0.876$ bits	$1 - 0.876 = 0.124$ bits
$N_1 > 7$	6+, 7-	2+, 1-	$H(6/13, 7/13) = 0.996$ bits	$H(2/3, 1/3) = 0.918$ bits	$13/16 * 0.996 + 3/16 * 0.918 = 0.981$ bits	$1 - 0.981 = 0.019$ bits

$N_1 > 8$	8+, 8-	0+, 0-	1 bit	--	$16/16 * 1 + 0/16 * -- = 0$ bits	$1 - 1 = 0$ bits
-----------	--------	--------	-------	----	----------------------------------	------------------



En verde he marcado la pregunta sobre N_1 que ofrece una mayor ganancia de información. Por otra parte, como se puede ver en la tabla, la pregunta sobre el valor más alto del atributo ($N_1 > 6$) clasifica a todos los ejemplos por la rama del “No”, y a ninguno por la rama del “Sí”. Es decir, no hace nada ($IG=0$). Por tanto siempre podemos evitar chequear esta pregunta en C4.5.

Si ahora estudiamos las posibles preguntas con N_2 (la pregunta sobre el valor más alto, 26, no la chequeamos directamente por lo dicho en el anterior párrafo):

Pregunta	Rama “No”	Rama “Sí”	Entropía clase en Rama “No”	Entropía clase en Rama “Sí”	$H(\text{clase} \text{Pregunta})$	IG
$N_2 > 21$	2+, 2-	6+, 6-	$H(2/4, 2/4) = 1$ bits	$H(6/12, 6/12) = 1$ bits	$4/16 * 1 + 12/16 * 1 = 1$ bits	$1 - 1 = 0$ bits
$N_2 > 22$	3+, 3-	5+, 5-	$H(3/6, 3/6) = 1$ bits	$H(5/10, 5/10) = 1$ bits	$6/16 * 1 + 10/16 * 1 = 1$ bits	$1 - 1 = 0$ bits
$N_2 > 23$	3+, 4-	5+, 4-	$H(3/7, 4/7) = 0.985$ bits	$H(5/9, 4/9) = 0.991$ bits	$7/16 * 0.985 + 9/16 * 0.991 = 0.988$ bits	$1 - 0.988 = 0.012$ bits
$N_2 > 24$	4+, 6-	4+, 2-	$H(4/10, 6/10) = 0.971$ bits	$H(4/6, 2/6) = 0.918$ bits	$10/16 * 0.971 + 6/16 * 0.918 = 0.951$ bits	$1 - 0.951 = 0.049$ bits
$N_2 > 25$	7+, 8-	1+, 0-	$H(7/15, 8/15) = 0.997$ bits	$H(1/1, 0/1) = 0$ bits	$15/16 * 0.997 + 1/16 * 0 = 0.935$ bits	$1 - 0.894 = 0.065$ bits

Como vemos, la mejor pregunta que podemos hacer con N_2 es $N_2 > 25$.

Sin embargo, el IG de $N_2 > 25$ es menor que el de la mejor pregunta sobre N_1 ($N_1 > 6$) así que esta es la pregunta que escogeremos para el nodo raíz.



Expansión del árbol en A

Vemos que hay 4+ y 7- ejemplos, 11 en total.

Primero calculamos $H(\text{clase})$ en A, es decir, $H(4/11, 7/11) = 0.946$ bits.

Ahora analizamos las posibles preguntas sobre N_1 :



Pregunta	Rama "No"	Rama "Sí"	Entropía clase en Rama "No"	Entropía clase en Rama "Sí"	$H(\text{clase} \text{Pre-gunta})$	IG
$N_1 > 1$	2+, 1-	2+, 6-	$H(2/3, 1/3) =$ 0.918 bits	$H(2/8, 6/8) =$ 0.811 bits	$3/11 * 0.918 +$ $8/11 * 0.811$ $= 0.840$ bits	$0.946 - 0.840 =$ 0.106 bits
$N_1 > 2$	3+, 2-	1+, 5-	$H(3/5, 2/5) =$ 0.971 bits	$H(1/6, 5/6) =$ 0.650 bits	$5/11 * 0.971 +$ $6/11 * 0.650$ $= 0.796$ bits	$0.946 - 0.796 =$ 0.150 bits
$N_1 > 3$	3+, 4-	1+, 3-	$H(3/7, 4/7) =$ 0.985 bits	$H(1/4, 3/4) =$ 0.811 bits	$7/11 * 0.985 +$ $4/11 * 0.811$ $= 0.922$ bits	$0.946 - 0.922 =$ 0.024 bits
$N_1 > 4$	3+, 5-	1+, 2-	$H(3/8, 5/8) =$ 0.954 bits	$H(1/3, 2/3) =$ 0.918 bits	$8/11 * 0.954 +$ $3/11 * 0.918$ $= 0.944$ bits	$0.946 - 0.944 =$ 0.002 bits
$N_1 > 5$	3+, 6-	1+, 1-	$H(3/9, 6/9) =$ 0.918 bits	$H(1/2, 1/2) =$ 1 bits	$9/11 * 0.918 +$ $2/11 * 1$ $= 0.933$ bits	$0.946 - 0.933 =$ 0.013 bits

En verde he marcado la pregunta sobre N_1 que ofrece una mayor ganancia de información. Si ahora hacemos lo mismo para N_2 :

Pregunta	Rama "No"	Rama "Sí"	Entropía clase en Rama "No"	Entropía clase en Rama "Sí"	$H(\text{clase} \text{Pre-gunta})$	IG
$N_2 > 21$	2+, 1-	2+, 6-	$H(2/3, 1/3) =$ 0.918 bits	$H(2/8, 6/8) =$ 0.811 bits	$3/11 * 0.918 +$ $8/11 * 0.811$ $= 0.840$ bits	$0.946 -$ $0.840 =$ 0.106 bits
$N_2 > 22$	3+, 2-	1+, 5-	$H(3/5, 2/5) =$ 0.971 bits	$H(1/6, 5/6) =$ 0.650 bits	$5/11 * 0.971 +$ $6/11 * 0.650$ $= 0.796$ bits	$0.946 -$ $0.796 =$ 0.150 bits
$N_2 > 23$	3+, 3-	1+, 4-	$H(3/6, 3/6) =$ 1 bits	$H(1/5, 4/5) =$ 0.722 bits	$6/11 * 1 +$ $5/11 * 0.722$ $= 0.874$ bits	$0.946 -$ $0.874 =$ 0.072 bits
$N_2 > 24$	3+, 5-	1+, 2-	$H(3/8, 5/8) =$ 0.954 bits	$H(1/3, 2/3) =$ 0.918 bits	$8/11 * 0.954 +$ $3/11 * 0.918$ $= 0.944$ bits	$0.946 -$ $0.944 =$ 0.002 bits

Como vemos, la mejor pregunta sobre N_2 "empata" con la mejor pregunta sobre N_1 (tienen exactamente la misma IG). Aunque los valores los hemos redondeado a 3 cifras decimales, las IGs son exactamente las mismas (ambas preguntas separan a los patrones

en un subconjunto con 3+, 2- ejemplos y otro subconjunto con 1+, 5-). Vamos a suponer que en este caso de empate C4.5 elige N_2 (podría haber elegido N_1 , las dos preguntas son equivalentes en términos de información). Entonces:



Aunque es fácil ver qué va a pasar a continuación, vamos a hacer los cálculos.

Expansión del árbol en C

Vemos que en C hay 3+ y 2- ejemplos, 5 en total.

Primero calculamos $H(\text{clase})$ en C, es decir, $H(3/5, 2/5) = 0.971$ bits.


Posibles preguntas sobre N_1 :

Pregunta	Rama "No"	Rama "Sí"	Entropía clase en Rama "No"	Entropía clase en Rama "Sí"	$H(\text{clase} \text{Pregunta})$	IG
$N_1 > 1$	2+, 0-	1+, 2-	$H(2/2, 0/2) = 0$ bits	$H(1/3, 2/3) = 0.918$ bits	$2/5 * 0 + 3/5 * 0.918 = 0.551$ bits	$0.971 - 0.551 = 0.420$ bits
$N_1 > 2$	3+, 0-	0+, 2-	$H(3/3, 0/3) = 0$ bits	$H(0/2, 2/2) = 0$ bits	$3/5 * 0 + 2/5 * 0 = 0$ bits	$0.971 - 0 = 0.971$ bits
$N_1 > 5$	3+, 1-	0+, 1-	$H(3/4, 1/4) = 0.811$ bits	$H(0/1, 1/1) = 0$ bits	$4/5 * 0.811 + 1/5 * 0 = 0.649$ bits	$0.971 - 0.649 = 0.322$ bits

En verde he marcado la pregunta sobre N_1 que ofrece una mayor ganancia de información. Si ahora hacemos lo mismo para N_2 :


Pregunta	Rama "No"	Rama "Sí"	Entropía clase en Rama "No"	Entropía clase en Rama "Sí"	$H(\text{clase} \text{Pregunta})$	IG
$N_2 > 21$	2+, 1-	1+, 1-	$H(2/3, 1/3) = 0.918$ bits	$H(1/2, 1/2) = 1$ bits	$3/5 * 0.918 + 2/5 * 1 = 0.951$ bits	$0.971 - 0.951 = 0.020$ bits

Como vemos, la mejor pregunta sobre N_1 ($N_1 > 2$) tiene mayor IG que la mejor (única) pregunta sobre N_2 , por lo que será la que C4.5 elija. De hecho, $N_1 > 2$ separa perfectamente las clases: cuando C4.5 expanda recursivamente las dos ramas que cuelgan de esta pregunta (rama $N_1 > 2$ y rama $N_1 \leq 2$), C4.5 detectará que en cada una de ellas hay ejemplos de sólo una clase, por lo que pondrá una hoja en cada una de esas ramas con la clase mayoritaria y terminará su expansión:



Cuando C4.5 analice **D** encontrará que la mejor pregunta es $N_1 > 4$ (separa completamente las clases), y pone un nodo hoja en cada una de las dos ramas que cuelgan de esta pregunta. Y cuando C4.5 analice **B** encontrará que la mejor pregunta es $N_2 > 21$ (separa completamente las clases), y pone un nodo hoja en cada una de las dos ramas que cuelgan de esta pregunta.

Con lo cual, el árbol desarrollado por el algoritmo será:



4. Solución:

Patrón 1: $1.2 \cdot 0 - 0.7 \cdot 0 = 0$, que es < 0.3 , luego la salida de la neurona es 0

Patrón 2: $1.2 \cdot 0 - 0.7 \cdot 1 = -0.7$, que es < 0.3 , luego la salida de la neurona es 0

Patrón 3: $1.2 \cdot 1 - 0.7 \cdot 0 = 1.2$, que es > 0.3 , luego la salida de la neurona es 1

Patrón 4: $1.2 \cdot 1 - 0.7 \cdot 1 = 0.5$, que es > 0.3 , luego la salida de la neurona es 1

5. Solución:

$$h = \sigma(\mathbf{w}^T \cdot \mathbf{x})$$

$$\Delta \mathbf{w} = -\eta \cdot (h - t) \cdot \mathbf{x}$$

$\mathbf{x}^{(0)}$	$\mathbf{x}^{(1)}$	$\mathbf{x}^{(2)}$	t	w_0	w_1	w_2	h	$h-t$	Δw_0	Δw_1	Δw_2
1	0	0	0	-0.3	0	0.4	0.43	0.43	-0.43	0	0
1	1	0	0	-0.73	0	0.4	0.33	0.33	-0.33	-0.33	0
1	0	1	0	-1.06	-0.33	0.4	0.34	0.34	-0.34	0	-0.34
1	1	1	1	-1.4	-0.33	0.06	0.16	-0.84	0.84	0.84	0.84

Se llega tras la primera época a los siguientes pesos:

$$w_0 = -1.4 + 0.84 = -0.56$$

$$w_1 = -0.33 + 0.84 = 0.51$$

$$w_2 = 0.06 + 0.84 = 0.90$$

Extensión a la pregunta original:

¿Cuál sería el resultado de la primera época si en vez de aprendizaje online hubiéramos usado aprendizaje por lotes (batch) usando la misma constante de aprendizaje $\eta = 1$?

$\mathbf{x}^{(0)}$	$\mathbf{x}^{(1)}$	$\mathbf{x}^{(2)}$	t	w_0	w_1	w_2	h	$h-t$	Δw_0	Δw_1	Δw_2
1	0	0	0	-0.3	0	0.4	0.43	0.43	-0.43	0	0
1	1	0	0	-0.3	0	0.4	0.43	0.43	-0.43	-0.43	0
1	0	1	0	-0.3	0	0.4	0.52	0.52	-0.52	0	-0.52
1	1	1	1	-0.3	0	0.4	0.52	-0.48	0.48	0.48	0.48

Luego tras la primera época los pesos quedan del siguiente modo:

$$w_0 = -0.3 - 0.43 - 0.43 - 0.52 + 0.48 = -1.2$$

$$w_1 = 0 + 0 - 0.43 + 0 + 0.48 = 0.05$$

$$w_2 = 0.4 + 0 + 0 - 0.52 + 0.48 = 0.36$$

Nota: el cálculo que hemos realizado en aprendizaje por lotes es exactamente equivalente a la forma en la que viene en las transparencias de clase: calcular primero el gradiente debido a todos los patrones y después actualizar una sola vez los pesos con este gradiente (pasos 2.2 y 2.3 de la transparencia 23 de redes neuronales).